

Predição do sexo de galinhas-d'angola (*Numida meleagris*) utilizando medidas morfométricas e algoritmos de aprendizado de máquina

Autores

Afiliações

Autor correspondente

Abstract

Keywords

1. Introdução

A galinha-d'angola, originária do continente africano, representa uma fonte alternativa de renda e proteína animal de fácil acesso, especialmente para as comunidades rurais. Apesar de já existirem dados e estudos sobre seus sistemas de produção, ainda há muitos aspectos a serem investigados; a diversidade genética e métodos de sexagem dessa espécie permanecem pouco compreendidos na maioria dos países. Nesse contexto, essa ave tem sido amplamente estudada, visando sua aplicação em programas de melhoramento genético e no desenvolvimento de sistemas de produção avícola (DONGMO DJIOTSA et al., 2023; MOREKI; SEABO, 2012).

Embora possua características produtivas favoráveis, a exploração comercial da galinha-d'angola ainda enfrenta obstáculos no que diz respeito à determinação precoce do sexo dos animais. Diferente das espécies avícolas que apresentam dimorfismo sexual evidente nas fases iniciais de desenvolvimento, as galinhas-d'angola apresentam alta similaridade fenotípica durante a maior parte do seu desenvolvimento, o que torna a distinção do sexo por métodos visuais convencionais, bastante desafiadora (ABDUL-RAHMAN et al., 2015; YAKUBU et al., 2022).

A determinação precoce do sexo em aves é uma ferramenta importante para programas de seleção e manejo reprodutivo. Para esse fim, diversos métodos têm sido utilizados, como avaliação comportamental, inspeção da cloaca, vocalização e técnicas moleculares baseadas em marcadores associados aos cromossomos sexuais. Embora os métodos moleculares ofereçam alta precisão, sua utilização pode ser restringida devido aos custos do laboratório, equipamentos especializados e ao tempo necessário para processar as amostras (FRIDOLFSSON; ELLEGREN, 1999; GRIFFITHS et al., 1998).

Como estratégia viável, a utilização de características morfométricas se apresenta como uma alternativa simples, rápida e econômica para a determinação do sexo. Pesquisas conduzidas em diversas espécies de aves demonstraram que as medidas corporais podem apresentar associação com o sexo dos indivíduos, possibilitando a criação de modelos preditivos fundamentados em características fenotípicas. Em galinhas-d'angola

características como peso corporal, comprimento da asa, comprimento da canela, comprimento corporal e medidas cefálicas, têm sido investigadas como possíveis indicadores de dimorfismo sexual (YAKUBU et al., 2022; MUSUNDIRE; HALIMANI; CHIMONYO, 2018; DUDUSOLA; BASHIRU; ADEWUYI, 2021).

Para além das análises estatísticas convencionais, avanços na ciência de dados têm expandido o uso de algoritmos de aprendizado de máquina em estudos zootécnicos. Métodos como Support Vector Machine (SVM), Random Forest, Gradient Boosting e Extreme Gradient Boosting (XGBoost) são frequentemente utilizados para classificação, reconhecimento de padrões e tomada de decisões em sistemas de produção animal. Esses algoritmos têm a habilidade de reconhecer conexões difíceis entre variáveis biológicas, muitas vezes indo além das técnicas estatísticas tradicionais em tarefas de classificação (MONTEIRO; SANTOS; GONÇALVES, 2021; CURTI et al., 2023; TEDESCHI et al., 2025).

Apesar dos progressos recentes na utilização de algoritmos de aprendizado de máquina na produção animal, ainda há poucos estudos que investiguem seu uso para prever o sexo de galinhas-d'angola com base em medidas morfométricas obtidas ao longo do crescimento. Portanto, ainda não se sabe se essas características têm capacidade discriminatória suficiente para apoiar modelos preditivos confiáveis.

Portanto, o objetivo deste estudo foi avaliar o potencial de medidas morfométricas para predição do sexo em galinhas-d'angola (*Numida meleagris*) utilizando algoritmos de aprendizado de máquina.

2. Materiais e Métodos

2.1 Considerações éticas

Este estudo foi aprovado pelo Comitê de Ética no Uso de Animais da Universidade Federal do Piauí (CEUA/UFPI) sob protocolo nº 827/2024, em conformidade com a legislação brasileira sobre experimentação animal e com as diretrizes definidas pelo Conselho Nacional de Controle de Experimentação Animal (CONCEA).

2.2 Local de realização do experimento

O experimento foi conduzido no Setor de Avicultura do Departamento de Zootecnia do Centro de Ciências Agrárias da Universidade Federal do Piauí (DZO-CCA-UFPI), no *Campus* Ministro Petrônio Portela, situado em Teresina, Piauí, Brasil.

2.3 Animais, instalações e manejo

Foram utilizados um total de 235 pintainhos de galinhas-d'angola com um dia de vida. As aves foram alojadas em box experimental com área de 2,6m² distribuídos em um galpão de alvenaria com uma área total de 85m². O galpão possui piso de concreto, coberto por telhas de cerâmica e provido de ventilação natural.

Os compartimentos foram equipados com bebedouros de pressão, comedouros suspensos, um sistema de aquecimento nos 10 primeiros dias de vida das aves e camas feitas de palha de arroz. Foi estabelecida uma densidade de alojamento de oito aves por box.

Ao longo de todo o período experimental as aves tiveram acesso a água potável e ração, sendo a dieta formulada à base de milho e farelo de soja, atendendo as exigências nutricionais para cada fase de criação.

O programa de vacinação incluiu imunização contra doenças de Newcastle e bronquite infecciosa aos sete dias de vida, além da vacinação contra a boubá aviária aos 21 dias de idade, de acordo com as recomendações dos fabricantes.

2.4 Determinação do sexo

O sexo das aves foi identificado por meio de análise molecular de DNA. Foram coletadas amostras de sangue no primeiro dia de vida e encaminhadas ao Zoogene Laboratório Animal, localizado na Rua Atenas, nº257, Bairro Prado, Belo Horizonte, Minas Gerais, Brasil, especializado em diagnóstico molecular e sexagem de aves.

Os resultados de sexagem obtidos pelo laboratório foram utilizados para classificar os pintainhos em machos e fêmeas, constituindo a variável resposta empregada no treinamento e validação dos modelos de aprendizado de máquina.

Com base nos resultados da sexagem molecular, os 235 pintainhos avaliados foram classificados em 134 machos e 101 fêmeas.

2.5 Avaliação morfométrica

As medidas biométricas foram coletadas periodicamente em onze momentos distribuídos ao longo do crescimento das aves, do 1º ao 116º dias de idade, permitindo acompanhar o desenvolvimento corporal ao longo das diferentes fases de criação.

As mensurações foram realizadas semanalmente durante o primeiro mês de criação e, posteriormente, em intervalos de 10 a 21 dias, abrangendo as 235 aves avaliadas durante o período experimental.

Foram mensuradas as seguintes características: peso corporal, circunferência abdominal, circunferência da cabeça, comprimento do bico, comprimento do pescoço,

comprimento da asa, comprimento do dorso, comprimento da coxa, comprimento da canela, comprimento da sobrecoxa, comprimento do ventre, comprimento da tulipa e comprimento da unha maior.

O peso corporal foi medido individualmente utilizando uma balança eletrônica digital de precisão (modelo SF-400, capacidade máxima de 10 kg e resolução de 1 g) sendo expresso em gramas (g), e as medidas lineares e de circunferência foram realizadas utilizando uma fita métrica graduada, com resolução de 1 mm sendo expressas em centímetros (cm).

Todas as características morfométricas foram consideradas variáveis preditoras nos modelos de classificação do sexo, e as mensurações realizadas pela mesma equipe, seguindo protocolo padronizado de aferição, com o objetivo de minimizar erros de mensuração e reduzir a variabilidade entre observadores.

2.6 Construção e organização do banco de dados

As análises morfométricas foram realizadas em 235 aves. No entanto, um indivíduo foi excluído das análises estatísticas e do desenvolvimento dos modelos por não apresentar informação referente ao sexo, resultando em um banco de dados final de 234 indivíduos. As informações coletadas durante as avaliações morfométricas foram organizadas em planilhas no programa Microsoft Excel® (Microsoft Corporation, Redmond, WA, EUA), nas quais cada linha representou uma observação única e cada coluna uma variável avaliada.

Antes das análises, foi realizada uma revisão criteriosa do banco de dados para detectar registros inconsistentes, erros de digitação, duplicidades e valores extremos (*outliers*), para assegurar a integridade e qualidade das informações utilizadas nas etapas seguintes.

O delineamento metodológico adotado neste estudo é apresentado de forma esquemática na Figura 1.




Figura 1. Fluxograma das etapas metodológicas empregadas no desenvolvimento dos modelos de aprendizado de máquina para predição do sexo de galinhas-d'angola (*Numida meleagris*), incluindo obtenção dos dados, análises exploratórias, pré-processamento, treinamento, validação e avaliação dos algoritmos.

2.7 Análise estatística exploratória

Inicialmente foi realizada a caracterização descritiva das variáveis morfométricas de machos e fêmeas por meio do software RStudio (versão 2026.06.1). Foram analisados o número de observações (N), a média, o desvio-padrão (DP), o coeficiente de variação (CV), além dos valores mínimos e máximos para cada característica avaliada.

Em seguida, a distribuição das variáveis foi avaliada por meio do teste de normalidade Shapiro-Wilk. Embora esse teste tenha revelado desvios de normalidade em algumas variáveis, seus resultados foram utilizados apenas para caracterização do conjunto de dados, não sendo empregados como critério para exclusão de observações ou seleção de modelos, uma vez que os algoritmos de aprendizado de máquina utilizados neste estudo não pressupõem distribuição normal das variáveis preditoras.

Como análise exploratória complementar, foi construída uma matriz de correlação de Spearman para avaliar a relação entre as variáveis morfométricas. Além disso, foram realizadas a Análise de Componentes Principais (PCA) e Análise Discriminante Linear (LDA), utilizando a biblioteca Scikit-learn em Python. Essas análises tiveram como objetivo

explicar a estrutura multivariada dos dados e avaliar a eficácia das características morfométricas na distinção entre machos e fêmeas.

2.8 Pré-processamento dos dados

Para as análises estatísticas exploratórias dos dados, foi utilizado o conjunto completo de informações, que incluía todas as mensurações obtidas ao longo do período experimental. Para o desenvolvimento dos modelos de aprendizagem de máquina, o banco de dados foi transferido para o ambiente de programação em Python (versão 3.11) e submetido às etapas de pré-processamento descritas a seguir.

Inicialmente, as variáveis morfométricas foram convertidas em formato numérico. Em seguida foram removidos os registros que continham valores ausentes nas variáveis preditoras ou na variável resposta, bem como faixas etárias que apresentavam menos de dez observações, resultando em um conjunto final de dados com 2.278 observações. O sexo foi codificado numericamente, atribuindo o valor de 0 para fêmeas e 1 para machos.

Posteriormente, as variáveis quantitativas foram padronizadas utilizando o método `StandardScaler`, baseado na transformação z-score, permitindo que todas as características contribuíssem de forma equivalente durante o treinamento dos modelos, independentemente de suas escalas originais de medida.

Para evitar vazamento de informações (*data leakage*), a divisão entre os conjuntos de treinamento e teste foi realizada considerando cada indivíduo como unidade experimental, impedindo que registros provenientes da mesma ave fossem utilizados simultaneamente em ambos os conjuntos. A divisão adotada correspondeu a 80% dos dados para treinamento e 20% para teste, utilizando `random state = 42`, garantindo reprodutibilidade das análises.

2.9 Desenvolvimento dos modelos de aprendizado de máquina

A predição do sexo foi realizada utilizando oito algoritmos de aprendizado de máquina: Support Vector Machine (SVM), Random Forest, Extra Trees, Gradient Boosting, Extreme Gradient Boosting (XGBoost), LightGBM, K-Nearest Neighbors (KNN) e Regressão Logística.

A otimização dos hiperparâmetros foi executada com a utilização do algoritmo `RandomizedSearchCV`, possibilitando a busca automática pelas melhores combinações de hiperparâmetro para cada um dos modelos. No que se refere a classificação do sexo, o critério adotado para a escolha dos modelos foi o F1-score, por oferecer uma métrica equilibrada entre precisão e sensibilidade, sendo particularmente indicada para conjunto de dados com distribuição desigual entre as classes.

2.10 Balanceamento das classes

Em razão do desbalanceamento entre os números de machos e fêmeas presentes no banco de dados, foi utilizada a técnica Synthetic Minority Over Sampling Technique (SMOTE), que foi aplicada exclusivamente aos conjuntos de treinamento ao longo do processo de validação cruzada.

Essa estratégia permitiu a criação de amostras sintéticas da classe menos representada através de interpolação entre dados próximos reduzindo o viés dos modelos em prol da classe mais numerosa.

2.11 Validação dos modelos

A confirmação dos modelos ocorreu através da validação cruzada estratificada (Stratified K-Fold), empregando cinco divisões ($k = 5$), com a organização aleatória dos dados (`shuffle = True`) e `random state = 42`.

A abordagem estratificada assegurou que cada grupo preservasse proporções parecidas entre machos e fêmeas, possibilitando avaliações mais sólidas sobre a eficácia dos algoritmos.

2.12 Avaliação do desempenho dos modelos

O desempenho dos algoritmos foi verificado utilizando métricas como: acurácia, precisão, sensibilidade, F1-score e a área sob a curva ROC.

Foram elaboradas matrizes de confusão para uma avaliação minuciosa dos acertos e erros nas classificações, além de curva ROC para examinar a habilidade discriminativa dos modelos.

Adicionalmente, foi feita uma análise sobre a importância das variáveis para o modelo que apresentou o melhor desempenho, com intuito de determinar a contribuição relativa de cada característica morfométrica na predição do sexo.

2.13. Ambiente computacional

Todas as etapas de pré-processamento dos dados, desenvolvimento, treinamento, validação e avaliação dos modelos de aprendizado de máquina, foram conduzidas em Python (versão 3.11).

Para a implementação das análises computacionais foram utilizadas as bibliotecas Pandas, NumPy, Scikit-learn, XGBoost, LightGBM, Imbalanced-learn, SciPy, Matplotlib, Seaborn e Joblib.

3. Resultados

A análise descritiva das características morfométricas está apresentada na Tabela 1. O número de observações (N) variou de 2.288 a 2.300, em decorrência da falta de registros para algumas variáveis. As médias mostraram a amplitude das medidas ao longo do período experimental. Os coeficientes de variação variaram entre 23,91% (circunferência da cabeça) a 80,68% (peso corporal), indicando maior variabilidade nesta última característica.

O teste de normalidade de Shapiro–Wilk resultou na rejeição da hipótese de normalidade para todas as variáveis ($p < 0,001$). No entanto, os valores da estatística W se mantiveram relativamente elevados (0,9113–0,9677), sugerindo que a distribuição é próxima da normalidade para a maioria das características morfométricas.

Esses resultados forneceram a caracterização inicial do conjunto de dados utilizados nas análises subsequentes.

Tabela 1. Estatística descritiva e teste de normalidade das características morfométricas avaliadas em galinhas-d'angola (*Numida meleagris*).

Variável	N	Média $\pm$ DP	CV (%)	Mínimo	Máximo	W	p-valor
Peso	2300	589,00 $\pm$ 475,22	80,68	20,0	1905,0	0,9113	<0,001
Bico	2292	1,89 $\pm$ 0,62	32,60	0,4	8,0	0,9660	<0,001
Circunferência da cabeça	2291	9,61 $\pm$ 2,30	23,91	2,4	17,0	0,9677	<0,001
Pescoço	2290	10,48 $\pm$ 5,14	49,02	1,0	37,0	0,9370	<0,001
Asa	2291	10,87 $\pm$ 4,53	41,73	1,0	34,5	0,9504	<0,001
Tulipa	2290	5,44 $\pm$ 2,36	43,37	0,7	19,0	0,9638	<0,001
Dorso	2288	29,33 $\pm$ 11,99	40,89	2,5	66,0	0,9475	<0,001
Ventre	2290	27,14 $\pm$ 11,05	40,72	8,6	55,0	0,9456	<0,001
Circunferência abdominal	2290	21,45 $\pm$ 9,88	46,05	5,7	48,0	0,9384	<0,001
Sobrecoxa	2290	7,37 $\pm$ 3,36	45,62	2,0	42,0	0,9258	<0,001
Coxa	2291	7,92 $\pm$ 3,50	44,23	0,1	42,0	0,9308	<0,001
Canela	2290	5,24 $\pm$ 2,12	40,35	1,4	11,0	0,9489	<0,001
Unha maior	2289	5,09 $\pm$ 2,03	39,81	1,1	10,0	0,9654	<0,001

Abreviações: N = número de observações; DP = desvio-padrão; CV = coeficiente de variação; W = estatística do teste de Shapiro–Wilk.

A Figura 2 apresenta uma distribuição das principais características morfométricas entre machos e fêmeas. Observa-se uma ampla sobreposição entre os sexos em todas as variáveis analisadas, como peso corporal, comprimento da canela, circunferência abdominal

e circunferência da cabeça. Apesar de pequenas diferenças serem identificadas nas medianas, a grande dispersão nos valores reforça a baixa distinção morfológica entre machos e fêmeas.




Figura 2. Distribuição das principais variáveis morfométricas utilizadas para a classificação do sexo de galinhas-d'angola (*Numida meleagris*): (A) canela, (B) circunferência abdominal, (C) circunferência da cabeça e (D) peso corporal.

A matriz de correlação de Spearman entre as variáveis é apresentada na Figura 3. Uma alta correlação positiva entre todas as características estudadas foi observada, com coeficiente variando de 0,80 a 0,96. As correlações mais elevadas foram identificadas entre o peso corporal e a circunferência abdominal ($p=0,96$), peso corporal e dorso ($p=0,95$), assim como entre a circunferência abdominal e dorso ($p=0,95$). Esses resultados sugerem que as medidas biométricas refletiram um crescimento sincronizado durante o desenvolvimento das aves, evidenciando uma elevada correlação entre as variáveis avaliadas.




Figura 3. Matriz de correlação de Spearman entre as variáveis morfométricas avaliadas em galinhas-d'angola (*Numida meleagris*).

A análise de Componentes Principais (PCA) revelou uma grande sobreposição entre machos e fêmeas, como indicado na Figura 4, sem apresentar a formação de grupos claramente distintos. O primeiro componente principal foi responsável por explicar cerca de 83% da variação total nos dados, estando fortemente relacionado ao tamanho corporal e à idade dos animais. No entanto, mesmo com a análise conjunta das variáveis morfométricas, não foi possível identificar uma separação evidente entre os sexos.




Figura 4. Análise de Componentes Principais (PCA) das variáveis morfométricas de galinhas-d'angola (*Numida meleagris*), considerando a distribuição de machos e fêmeas.

A Análise Discriminante Linear (Figura 5) revelou uma considerável sobreposição entre as distribuições dos escores do primeiro discriminante linear (LD1) entre machos e fêmeas, o que indica uma baixa capacidade das variáveis morfométricas para distinguir os sexos. Apesar da média dos machos ser um pouco superior às das fêmeas, conforme indicado pelas linhas tracejadas, a considerável interseção entre as curvas evidencia a limitada capacidade discriminatória das características morfométricas avaliadas. Esse padrão foi consistente com os achados da Análise de Componentes Principais (PCA), reforçando a alta similaridade morfológica entre machos e fêmeas ao longo do período experimental.




Figura 5. Distribuição dos escores do primeiro discriminante linear (LD1) obtidos por Análise Discriminante Linear (LDA) para machos e fêmeas de galinhas-d'angola (*Numida meleagris*). As curvas representam a densidade dos escores discriminantes de cada sexo, enquanto as linhas tracejadas indicam a média dos escores para machos e fêmeas.

O desempenho dos oito algoritmos de aprendizado de máquina empregados na predição do sexo de galinhas-d'angola está descrito na Tabela 2. Dentre os modelos analisados, o XGBoost exibiu o melhor desempenho geral, atingindo uma acurácia de 58,72%, precisão de 58,69%, sensibilidade de 58,72% e um F1-score de 58,7%. Os modelos Gradientes Boosting e Random Forest exibiram desempenhos semelhantes, ao passo que a Regressão Logística apresentou o pior desempenho em todas as métricas analisadas.

Tabela 2. Desempenho dos algoritmos utilizados para classificação do sexo.

Algoritmo	<u>Accuracy</u>	<u>Precision</u>	Recall	F1-score
XGBoost	0.5872	0.5869	0.5872	0.5870
Gradient Boosting	0.5784	0.5722	0.5784	0.5743
Random Forest	0.5695	0.5644	0.5695	0.5664
Extra Trees	0.5563	0.5524	0.5563	0.5540
KNN	0.5497	0.5681	0.5497	0.5532
LightGBM	0.5430	0.5412	0.5430	0.5421
SVM	0.5298	0.5356	0.5298	0.5321
Regressão Logística	0.5011	0.5201	0.5011	0.5050

Com base no melhor resultado dos modelos testados, o algoritmo XGBoost foi selecionado para análises adicionais de desempenho e de interpretação.

A discriminação do modelo foi avaliada por meio da curva ROC (Figura 6). XGBoost alcançou área sob a curva (AUC) de 0,601 no conjunto de testes e apresentou AUC média de 0,564 na validação cruzada, sinalizando desempenho acima do esperado para um classificador aleatório.




Figura 6. Curva ROC do modelo XGBoost para classificação do sexo de galinhas-d'angola.

A matriz de confusão do modelo XGBoost (Tabela 3) indicou que 92 fêmeas e 174 machos foram identificados corretamente, enquanto 94 fêmeas foram classificadas incorretamente como machos e 93 machos foram classificados incorretamente como fêmeas.

Tabela 3. Matriz de confusão do modelo XGBoost.

Sexo real	Predito Fêmea	Predito Macho
Fêmea	92	94
Macho	93	174

A figura 7 mostra a relevância das variáveis morfométricas utilizadas na distinção do sexo. A variável com a maior influência no modelo foi a idade (0,084), seguida pelo comprimento da canela (0,083), comprimento da unha maior (0,079), circunferência abdominal (0,077) e circunferência da cabeça (0,075). O peso corporal, o comprimento da coxa e o comprimento do dorso tiveram importância semelhantes (0,073), enquanto o comprimento do bico (0,066), sobrecoxa (0,065) ventre (0,065), tulipa (0,064), pescoço (0,063) e asa (0,059) apresentaram contribuições ligeiramente menores.

Observou-se uma distribuição uniforme entre as variáveis, sugerindo que nenhuma das características morfométricas, de forma isolada, demonstrou elevada capacidade de distinguir o sexo dessas aves.




Figura 7. Importância relativa das variáveis morfométricas para classificação do sexo utilizando o algoritmo XGBoost.

4. Discussão

Na análise morfométrica dos dados foi possível observar uma extensa variedade nas características avaliadas, refletindo que as alterações estruturais ocorreram conforme as

galinhas-d'angola se desenvolveram durante o período do experimento. O peso corporal apresentou o maior índice de variação (80,68%), enquanto a média da circunferência da cabeça apresentou a menor variação relativa (23,91%), sugerindo que diferentes características anatômicas seguem ritmos variados de crescimento e desenvolvimento. Esse padrão era previsível, uma vez que, as medições englobam aves desde o primeiro até o 116º dia de idade, um período marcado por um intenso acúmulo de tecidos, crescimento ósseo e desenvolvimento muscular. A idade exerce uma significativa influência nas dimensões corporais, sendo um dos principais fatores que contribuem para o aumento da variação fenotípica em aves domésticas, particularmente quando o indivíduo de diferentes fases de crescimento são avaliados em conjunto (FARAJI-AROUGH; DASHAB; ROKOUEI, 2026).

O alto coeficiente de variação está diretamente ligado com a natureza dinâmica dessa característica. Ao contrário das medidas lineares, o peso corporal representa uma variável complexa e multifatorial, sendo o resultado da interação conjunta dos fatores como o crescimento ósseo, o desenvolvimento da musculatura, o acúmulo de gordura, além de ser influenciado por fatores genéticos, nutricionais, fisiológicos e ambiental (MAHARJAN et al., 2021; WANG et al., 2017).

Estudos sobre crescimento em diferentes linhagens de galinhas-d'angola indicam que o aumento do peso ocorre de forma rápida nas primeiras semanas de vida, diminuindo após o ponto de curvatura da curva de crescimento. Assim, quando as aves com idades diversas são analisadas em um único conjunto de dados, a variação de pesos se torna elevada aumentando naturalmente o coeficiente de variação (FARAJI-AROUGH; DASHAB; ROKOUEI, 2026). Faraji-Arough et al. (2026) mostraram que o peso total das aves é a característica que mais sofre mudanças durante o crescimento para a espécie *Numida meleagris*, enfatizando que essa alteração está ligada principalmente à idade dos animais e as diversas taxas de crescimento entre eles.

Esses resultados estão de acordo com os achados de Yakubu et al. (2022), que ao caracterizarem as populações de galinhas-d'angola nativas da Nigéria por meio de métodos multivariados, encontraram uma alta heterogeneidade nas medições corporais, principalmente no peso vivo, comprimento do corpo e outras características relacionadas ao tamanho do animal. De acordo com os autores, parte dessas variações é atribuída a diferenças genéticas entre as populações, mas a idade continua sendo um dos principais fatores que influenciam a variação fenotípica observada entre os indivíduos. Além disso, destacam que o crescimento das galinhas-d'angola não se dá de forma uniforme em diversas regiões do corpo, resultando em algumas estruturas apresentando um desenvolvimento mais precoce, enquanto outras continuam a crescer por um período mais longo.

Esses achados também estão alinhados com os relatados por Abdul-Rahman *et al.* (2015), que avaliaram as características morfométrica de galinhas-d'angola com o objetivo de desenvolver métodos biométricos para a identificação do sexo. Os autores verificaram que a maior parte das características corporais analisadas apresentou comportamento similar entre os machos e as fêmeas quando avaliadas de forma individual, evidenciando que o dimorfismo sexual nesta espécie é sutil e que as medições biométricas individuais têm a capacidade restrita de distinção. De acordo com os autores, a utilização de várias características em modelos multivariados melhora significativamente a capacidade de classificar os indivíduos, mostrando que a análise conjunta das informações biométricas é mais ineficaz do que a avaliação separada de cada variável.

Em contrapartida, na circunferência da cabeça mostrou o menor índice de variação entre todas as variáveis analisadas. Esse achados indica que as estruturas do crânio tendem a se desenvolver de maneira relativamente precoce e possuem menos flexibilidade morfológica durante o crescimento em comparação com as estruturas do tronco e dos membros. Em aves, o desenvolvimento do crânio geralmente ocorre rapidamente nas fases iniciais de vida, período em que os elementos cranianos sofrem rápida ossificação se estabilizando antes que as características ligadas ao aumento de peso corporal se tornem evidentes. Após essa fase, a taxa de crescimento craniano diminui significativamente enquanto o crescimento corporal continua de forma mais acentuada (ARNAOUT *et al.*, 2021). Dudusola *et al.* (2021), ao estudarem diferentes variedades de galinhas-d'angola adultas, também, notaram que certas medidas da cabeças mostram menos variabilidade em relação a características como peso e comprimento, destacando que diversas partes anatômicas reagem de forma diferente ao crescimento corporal.

Outro aspecto importante diz respeito ao impacto da idade em todas as características morfométricas avaliadas. O desenvolvimento das aves é um processo holístico que inclui mudanças no tamanho ósseo, no crescimento da musculatura esquelética, e na evolução dos tecidos do corpo, de tal forma que quase todas as medições biométricas mudam nas primeiras semanas de vida (MAHARJAN *et al.*, 2021; BUZALA; JANICKI, 2016).

Estudos recentes sobre a genética e fenotipagem de galinhas-d'angola mostraram que fatores como o comprimento da canela, o tamanho da coxa, a circunferência do abdômen e o peso do corpo estão intimamente associados à idade podendo ser considerados indicadores do crescimento físico e do desempenho produtivo dos animais (OROUNLADJI *et al.*, 2025). Essa relação etária não apenas explica a variação nas medições descritivas mas também a elevada correlação observada posteriormente entre várias características morfométricas deste estudo.

A análise da normalidade através do teste de Shapiro-Wilk demonstrou a rejeição da suposição de que as variáveis analisadas seguem uma distribuição normal. No entanto, esse resultado deve ser interpretado considerando o elevado tamanho amostral utilizado neste estudo. Apesar de todos os valores de p terem sido abaixo de 0,001, os coeficientes da estatística W se mantiveram altos (0,9113-0,9677), sugerindo que os desvios em relação à distribuição normal foram relativamente pequenos.

Em conjuntos de dados que incluem muitas observações, como no presente trabalho, o teste de Shapiro-Wilk possui alta potência estatística para identificar pequenas variações entre a distribuição real e a normal teórica, frequentemente resultando em conclusões estatisticamente significativas, mesmo quando as distribuições parecem visualmente similares à normalidade. Essa característica já foi amplamente debatida na literatura estatística, que aconselha a interpretação conjunta dos valores de p , o tamanho da amostra e a análise gráfica dos dados antes de chegar a uma conclusão sobre a conformidade da distribuição (GHASEMI; ZAHEDIASL, 2012; MISHARA et al., 2019; RAZALI; WAH, 2011).

Sob a perspectiva do aprendizado de máquina, a falta de normalidade não se configura como uma restrição metodológica significativa. Ao contrário dos métodos estatísticos paramétricos convencionais, algoritmos como Random Forest, Gradient Boosting, XGBoost, LightGBM e Support Vector Machine não necessitam que as variáveis preditoras sigam uma distribuição normal, sendo aptos a modelar relações complexas e não lineares entre dados (BREIMAN, 2001; CORTES; VAPNIK, 1995; FRIEDMAN, 2001; CHEN; GUESTRIN, 2016; KE et al., 2017).

Desse modo, a análise descritiva realizada neste estudo teve como foco principal descrever a estrutura do conjunto de dados e entender o comportamento das variáveis morfométricas antes das fases de redução de dimensionalidade e da criação dos modelos preditivos. A considerável variabilidade constante, principalmente para característica ligadas ao crescimento corporal, demonstra que o banco de dados apresenta uma ampla diversidade fenotípica, o que é uma condição essencial para o treinamento de algoritmos de aprendizado de máquinas e para a avaliação de habilidades discriminatória das características morfométricas na previsão do sexo de galinhas-d'angola (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

A análise da matriz de correlação de Spearman mostrou relações positivas entre a maioria das características morfométricas analisadas, sugerindo que o crescimento das galinhas-d'angola ocorreu de maneira integrada durante todo o período do experimento. As correlações mais fortes foram encontradas entre as características ligadas ao comprimento do corpo, especialmente aquelas relacionadas ao peso, comprimento do dorso, circunferência abdominal, comprimento da coxa, e comprimento da canela. Esse padrão

indica que o aumento dessas estruturas ocorre de forma coordenada, refletindo o desenvolvimento biológico esperado para aves em crescimento, em que, diferentes áreas anatômicas crescem simultaneamente, ainda que em ritmos variados.

Resultados semelhantes foram observados por Yakubu *et al.* (2022), que encontraram relações significativas entre o peso dos animais e várias medidas morfométricas em galinhas-d'angola, evidenciando que esses fatores refletem constantemente o crescimento do corpo. Da mesma forma, Orounladji *et al.* (2025) ressaltaram que medidas lineares, como o comprimento do corpo, o comprimento da coxa e o comprimento da canela, possuem uma forte correlação com o peso vivo, sendo essenciais para entender o desenvolvimento morfológico e a variabilidade fenotípica da espécie.

Do ponto de vista biológico, essas relações refletem o padrão típico de crescimento das aves, em que, diferentes partes anatômicas se desenvolvem de maneira coordenada, embora cada uma tenha seu próprio ritmo de crescimento. Nahashon *et al.* (2006) mostraram que o crescimento das galinhas-d'angola acontece de forma integrada ao longo de seu desenvolvimento, envolvendo o crescimento simultâneo do esqueleto, dos músculos e das outras estruturas do corpo. Portanto, as correlações identificadas neste estudo reforçam que as características morfométricas servem como indicadores confiáveis do desenvolvimento corporal e podem ajudar a distinguir fenotipicamente os sexos. (YAKUBU *et al.*, 2022; NAHASHON *et al.*, 2006; OROUNLADJI *et al.*, 2025).

A forte relação observada entre as variáveis biométricas está diretamente ligada ao processo de crescimento corporal das aves. Nas primeiras semanas de vida, há um desenvolvimento simultâneo dos ossos, músculos e outros tecidos corporais, de forma que um aumento em uma característica geralmente leva a mudanças proporcionais em outras medidas morfométricas.

O crescimento unificado resulta em uma alta correlação entre características como o peso corporal, o comprimento da coxa, o comprimento do dorso, a circunferência do abdome refletindo diferentes aspectos de um único processo de desenvolvimento morfológico (NAHASHON *et al.*, 2006; MAHARJAN *et al.*, 2021). Esse modelo de ligação foi amplamente abordado em estudos de análise biométrica de galinhas-d'angola, nos quais, cada medida linear e o peso corporal demonstram fortes correlações devido à influência compartilhada do crescimento e da idade sobre esses fatores (YAKUBU *et al.*, 2022; OROUNLADJI *et al.*, 2025).

A elevada redundância observada entre as variáveis têm importantes implicações para o desenvolvimento de modelos preditivos. Quando trabalhamos com conjuntos de dados que possuem características fortemente correlacionadas, usar todas as variáveis ao mesmo tempo pode aumentar os efeitos da multicolinearidade em métodos estatísticos convencionais, afetando a confiabilidade dos coeficientes estimados e ampliando a

redundância das informações (JAMES et al., 2021). Por outro lado, algoritmos baseados em árvores de decisão como Random Forest, Gradient Boosting, XGBoost e LightGBM, são bastante resistentes a presença de variáveis correlacionadas, pois realizam a seleção automática dos atributos mais relevantes durante a elaboração das árvores, minimizando assim o impacto da redundância no desempenho preditivo (BREIMAN, 2001; FRIEDMAN, 2001; CHEN; GUESTRIN, 2016; KE et al., 2017).

Esse achado destaca a relevância de se empregar abordagens multivariadas na análise morfométrica desta espécie. Em estudos de biometria animal, a forte correlação entre as características corporais sugere que uma parte significativa da variação detectada é comum a diferentes medidas, o que torna os métodos multivariados, como a Análise de Componentes Principais (PCA), essenciais para diminuir a complexidade dos dados e reconhecer os padrões biológicos mais relevantes (JOLLIFFE, 2002; YAKUBU et al., 2022).

No presente estudo, a intensa relação entre as variáveis biométricas justifica, por tanto, o uso de técnicas que reduzem a dimensionalidade e algoritmos de aprendizado de máquina que são capazes de investigar interações complexas entre vários atributos ao mesmo tempo (HASTIE; TIBSHIRANI; FRIEDMAN, 2009; CHEN; GUESTRIN, 2016; KE et al., 2017). Apesar da alta correlação indicar uma redundância biológica entre algumas medidas corporais, isso não necessariamente constitui uma limitação para os modelos preditivos utilizados, mas sim revela que a determinação de várias características morfológicas, em vez de depender apenas da análise de um único atributo biométrico (BREIMAN, 2001; OROUNLADJI et al., 2025).

A Análise de Componentes Principais (PCA) mostrou que as duas primeiras componentes retêm uma parte significativa da variabilidade do conjunto de dados. Isso mostra que muitas informações das variáveis morfométricas podem ser condensadas em um número menor de componentes, o que é uma propriedade fundamental da PCA como uma método de redução de dimensionalidade (JOLLIFFE & CADIMA, 2016). No entanto, mesmo com essa diminuição da dimensionalidade, foi observada uma grande sobreposição entre os machos e as fêmeas no espaço multivariado. Isso indica que há uma estrutura morfológica suficientemente distinta para permitir uma separação natural entre os sexos através das combinações lineares das variáveis, sugerindo que as características biométricas analisadas têm um baixo poder de discriminação (ADAMS, ROHLF & SLICE, 2004).

Esse tipo de comportamento era esperado com base nos resultados da matriz de correlação de Spearman. A forte relação identificada entre o peso corporal, circunferência abdominal, comprimento da canela, do dorso, da coxa, e as demais características sugere que essas variáveis, em grande parte, refletem o mesmo processo biológico relacionado ao crescimento, mostrando uma intensa covariação devido ao tamanho dos indivíduos

(JOLICOEUR, 1963; KLINGENBERG, 2016). Como resultado a PCA concentrou a maior parte da variabilidade em um número reduzido de componentes principais, um comportamento que é esperado quando existe alta correlação entre as variáveis originais (JOLLIFFE & CADIMA, 2016). Assim, os primeiros componentes começaram a expressar principalmente variações no tamanho do corpo e no nível de desenvolvimento das aves, em vez de diferentes relacionados ao gênero (JOLICOEUR, 1963; KLINGENBERG, 2016).

Resultados semelhantes foram relatados por Yakubu et al. (2022), que aplicaram métodos multivariados para analisar populações nativas de galinhas-d'angola na Nigéria. Os autores verificaram que as primeiras componentes eram muito afetadas por atributos relacionados ao tamanho corporal, agrupando a maior parte da variabilidade econômica dos dados. Essas observações enfatizam que medidas biométricas que apresentam alta correlação contém informações repetitivas e podem ser resumidas em um número menor de componentes principais, com a capacidade de diferenciação da PCA sendo influenciada pela magnitude das variações morfológicas entre os grupos avaliados (JOLLIFFE & CADIMA, 2016; KLINGENBERG, 2016).

REFERÊNCIA

JOLICOEUR, P. Note: The multivariate generalization of the allometry equation. *Biometrics*, Washington, v. 19, n. 3, p. 497–499, 1963. DOI: <https://doi.org/10.2307/2527939>

CURTI, P. F. et al. Applications of livestock monitoring devices and machine learning in animal production. *Animal Reproduction*, v. 20, 2023. DOI: <https://doi.org/10.1590/1984-3143-AR2023-0077>.

DONGMO DJIOTSA, F. et al. Sistemas de produção e variabilidade fenotípica da pintada (*Numida meleagris*) na África Subsaariana. *Black Sea Journal of Agriculture*, v. 6, n. 6, p. 718-725, 2023. DOI: <https://doi.org/10.47115/bsagriculture.1339905>.

FRIDOLFSSON, A.-K.; ELLEGREN, H. A simple and universal method for molecular sexing of non-ratite birds. *Journal of Avian Biology*, v. 30, n. 1, p. 116-121, 1999. DOI: <https://doi.org/10.2307/3677252>.

GRIFFITHS, R.; DOUBLE, M. C.; ORR, K.; DAWSON, R. J. G. A DNA test to sex most birds. *Molecular Ecology*, v. 7, n. 8, p. 1071-1075, 1998. DOI: <https://doi.org/10.1046/j.1365-294x.1998.00389.x>.

MONTEIRO, A.; SANTOS, S.; GONÇALVES, P. Precision agriculture for crop and livestock farming: brief review. *Animals*, v. 11, n. 8, p. 2345, 2021. DOI: <https://doi.org/10.3390/ani11082345>.

MOREKI, J. C.; SEABO, D. Guinea fowl production in Botswana. *Journal of World's Poultry Research*, v. 2, n. 1, p. 1-4, 2012. Disponível em: <https://jwpr.science-line.com/attachments/article/12/JWPR.%20B1,%202012,%20%201-4.pdf>. Acesso em: 20 jun. 2026.

MUSUNDIRE, M. T.; HALIMANI, T. E.; CHIMONYO, M. Effect of age and sex on carcass characteristics and internal organ weights of scavenging chickens and helmeted guinea fowls. *Journal of Applied Animal Research*, v. 46, n. 1, p. 860-867, 2018. DOI: <https://doi.org/10.1080/09712119.2017.1411266>.

TEDESCHI, L. O. *et al.* Advancing precision livestock farming: integrating artificial intelligence and data-driven technologies into livestock production systems. 2025. DOI: <https://doi.org/10.5713/ab.25.0289>.

YAKUBU, A. *et al.* Multivariate characterisation of morpho-biometric traits of indigenous helmeted guinea fowl (*Numida meleagris*) in Nigeria. *PLoS ONE*, San Francisco, v. 17, n. 1, e0261048, 2022. DOI: <https://doi.org/10.1371/journal.pone.0261048>.

FARAJI-AROUGH, Hadi; DASHAB, Gholam Reza; ROKOUEI, Mohammad. **Modelling growth patterns of three guinea fowl varieties using non-linear models.** *Poultry Science*, v. 105, n. 2, e106297, 2026. DOI: <https://doi.org/10.1016/j.psj.2025.106297>

ABDUL-RAHMAN, I. I.; AWUMBILA, B.; JEFFCOATE, I. A.; ROBINSON, J. E.; OBESE, F. Y. **Sexing in guinea fowls (*Numida meleagris*).** *Poultry Science*, v. 94, n. 2, p. 311–318, 2015. DOI: <https://doi.org/10.3382/ps/peu067>

ARNAOUT, B.; LANTIGUA, K. E.; MACKENZIE, E. M.; MCKINNELL, I. W.; MADDIN, H. C. Development of the chicken skull: A complement to the external staging table of Hamburger and Hamilton. *The Anatomical Record*, v. 304, n. 12, p. 2726–2740, 2021. DOI: <https://doi.org/10.1002/ar.24603>

MAHARJAN, P.; MARTINEZ, D. A.; WEIL, J.; SUESUTTAJIT, N.; UMBERSON, C.; MULLENIX, G.; HILTON, K. M.; BEITIA, A.; COON, C. N. Review: Physiological growth trend of current meat broilers and dietary protein and energy management approaches for sustainable broiler production. *Animal*, v. 15, Suppl. 1, 100284, 2021. DOI: [10.1016/j.animal.2021.100284](https://doi.org/10.1016/j.animal.2021.100284)

WANG, G.; KIM, W. K.; CLINE, M. A.; GILBERT, E. R. Factors affecting adipose tissue development in chickens: A review. *Poultry Science*, v. 96, n. 10, p. 3687–3699, 2017. DOI: <https://doi.org/10.51791/njap.v48i2.2925>

DUDUSOLA, I. O.; BASHIRU, H. A.; ADEWUYI, A. A. Analysis of morphometric traits in heterogeneous population of adult guinea fowl (*Numida meleagris*). *Nigerian Journal of Animal Production*, v. 48, n. 2, p. 6–17, 2021. DOI: <https://doi.org/10.51791/njap.v48i2.2925>

MAHARJAN, P.; MARTINEZ, D. A.; WEIL, J.; SUESUTTAJIT, N.; UMBERSON, C.; MULLENIX, G.; HILTON, K. M.; BEITIA, A.; COON, C. N. Review: Physiological growth trend of current meat broilers and dietary protein and energy management approaches for sustainable broiler production. *Animal*, v. 15, Suppl. 1, 100284, 2021. DOI: <https://doi.org/10.1016/j.animal.2021.100284>

BUZALA, M.; JANICKI, B. Review: Effects of different growth rates in broiler breeder and layer hens on some productive traits. *Poultry Science*, v. 95, n. 9, p. 2151–2159, 2016. DOI: <https://doi.org/10.3382/ps/pew173>.

OROUNLADJI, B. M.; SOARA, A. E.; TOKOFAL, B. M.; CHRYSOSTOME, C. A. A. M.; TOZO, S. K.; DAYO, G.-K.; DOSSA, L. H. Advances in the genetic characterization of guinea fowl in Africa: a comprehensive overview of the current status, progress of genome genotyping, and future perspectives. *Poultry Science*, v. 104, n. 9, p. 105363, 2025. DOI: <https://doi.org/10.1016/j.psj.2025.105363>

GHASEMI, A.; ZAHEDIASL, S. Normality tests for statistical analysis: a guide for non-statisticians. *International Journal of Endocrinology and Metabolism*, v. 10, n. 2, p. 486–489, 2012. DOI: [10.5812/ijem.3505](https://doi.org/10.5812/ijem.3505)

MISHRA, P. et al. Descriptive statistics and normality tests for statistical data. *Annals of Cardiac Anaesthesia*, v. 22, n. 1, p. 67–72, 2019. DOI: [10.4103/aca.ACA_157_18](https://doi.org/10.4103/aca.ACA_157_18).

RAZALI, N. M.; WAH, Y. B. **Power comparisons of Shapiro-Wilk, Kolmogorov-Smirnov, Lilliefors and Anderson-Darling tests.** *Journal of Statistical Modeling and Analytics*, v. 2, n. 1, p. 21–33, 2011. Disponível em: <https://docslib.org/doc/4949053/power-comparisons-of-shapiro-wilk-kolmogorov-smirnov-lilliefors-and-anderson-darling-tests>. Acesso em: 22 jul. 2026.

BREIMAN, L. **Random forests.** *Machine Learning*, v. 45, n. 1, p. 5–32, 2001. DOI: <https://doi.org/10.1023/A:1010933404324>

Cortes, C., Vapnik, V. Redes de vetores de suporte. *Mach Learn* **20** , 273–297 (1995). DOI: <https://doi.org/10.1007/BF00994018>

FRIEDMAN, J. H. Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, v. 29, n. 5, p. 1189–1232, 2001. DOI: <https://doi.org/10.1214/aos/1013203451>.

CHEN, T.; GUESTRIN, C. XGBoost: A scalable tree boosting system. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge*

Discovery and Data Mining. New York: ACM, 2016. p. 785–794. DOI: <https://doi.org/10.1145/2939672.2939785>.

KE, G.; MENG, Q.; FINLEY, T.; WANG, T.; CHEN, W.; MA, W.; YE, Q.; LIU, T.-Y. LightGBM: A highly efficient gradient boosting decision tree. In: CONFERENCE ON NEURAL INFORMATION PROCESSING SYSTEMS (NEURIPS), 31., 2017, Long Beach. Proceedings [...] Long Beach: Neural Information Processing Systems Foundation, 2017. v. 30. Disponível em: https://proceedings.neurips.cc/paper_files/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html. Acesso em: 22 jul. 2026.

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. The elements of statistical learning: data mining, inference, and prediction. 2. ed. New York: Springer, 2009. DOI: <https://doi.org/10.1007/978-0-387-84858-7>.

OROUNLADJI, B. M.; SOARA, A. E.; TOKOFAL, B. M.; CHRYSOSTOME, C. A. A. M.; TOZO, S. K.; DAYO, G.-K.; DOSSA, L. H. Advances in the genetic characterization of guinea fowl in Africa: a comprehensive overview of the current status, progress of genome genotyping, and future perspectives. Poultry Science, v. 104, n. 9, 105363, 2025. DOI: <https://doi.org/10.1016/j.psj.2025.105363>.

NAHASHON, S. N.; AGGREY, S. E.; ADEFOPE, N. A.; AMENYENU, A. Modeling growth characteristics of meat-type guinea fowl. Poultry Science, v. 85, n. 5, p. 943–946, 2006. DOI: <https://doi.org/10.1093/ps/85.5.943>.

MAHARJAN, P.; MARTINEZ, D. A.; WEIL, J.; SUESUTTAJIT, N.; UMBERSON, C.; MULLENIX, G.; HILTON, K. M.; BEITIA, A.; COON, C. N. Review: Physiological growth trend of current meat broilers and dietary protein and energy management approaches for sustainable broiler production. Animal, v. 15, Suppl. 1, 100284, 2021. DOI: <https://doi.org/10.1016/j.animal.2021.100284>.

JOLLIFFE, I. T. Principal component analysis. 2. ed. New York: Springer, 2002. DOI: <https://doi.org/10.1007/b98835>.

ADAMS, D. C.; ROHLF, F. J.; SLICE, D. E. Geometric morphometrics: ten years of progress following the "revolution". Italian Journal of Zoology, v. 71, n. 1, p. 5–16, 2004. DOI: <https://doi.org/10.1080/11250000409356545>

JOLLIFFE, I. T.; CADIMA, J. Principal component analysis: a review and recent developments. Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences, v. 374, n. 2065, p. 20150202, 2016. DOI: [10.1098/rsta.2015.0202](https://doi.org/10.1098/rsta.2015.0202)

