

Previsão do Sexo e Peso de galinhas a partir das medidas corporais: Aplicações no Manejo Avícola

Betânia Dantas Liandro

Email: dantasliandrobetania@gmail.com

João Vitor Santana Lima

Email: joao.vitor.1@ufpi.edu.br

Orientador(a): Alcilene Dalília de Sousa

Resumo

O objetivo deste estudo foi desenvolver e avaliar modelos de aprendizado de máquina para a predição do peso corporal e a identificação do sexo da galinha-d'angola (*Numida meleagris*) a partir de medidas biométricas. Foram conduzidos três experimentos de algoritmo sendo eles XGBoost, SVM e Random Forest, utilizando técnica de busca de hiperparâmetros.

Palavra-chave: Galinhas d'angola, Weight and sex of guinea fowl, Peso e sexo em animais.

1 Introdução

Com o aumento da demanda por mais eficiência na criação de aves, surge também a necessidade de adotar tecnologia que facilitam o dia a dia no manejo. A ideia é conseguir, de maneira rápida, prática e segura, informações essenciais, sobre cada ave, como peso e sexo, contribuindo para um controle mais preciso e para melhorar os resultados na produção. Nas fases iniciais de desenvolvimento, as galinhas-d'angola apresentam grande semelhança entre si, o que dificulta a identificação do sexo por meio da observação visual.

A galinha-d’angola (*Numida meleagris*), pertencente à ordem dos Galliformes, é uma ave originária da África e foi introduzida no Brasil pelos colonizadores portugueses, provenientes da África Ocidental. No país, também é conhecida como guiné, galinha-do-mato, capote, capota, pintada, picote (na Amazônia) ou tô-fraca [1]. A diferenciação sexual da galinha d’angola se dá pelos diferentes sons que os machos apresentam em relação às fêmeas, sendo que essas emitem o característico “tô fraco”, enquanto que os machos emitem arrulhos e cacarejos [2].

Nesse contexto, o uso de técnicas de aprendizados de máquinas, surge como uma alternativa promissora para a predição corporal e a identificação do sexo da galinha-d’angola, a partir de medidas biométricas. Esses modelos possuem elevada capacidade de aprendizagem de padrões complexos e de modelagem de relações não lineares entre variáveis morfométricas e características produtivas. Dessa forma, possibilitam estimativas mais precisas e rápidas em comparação aos métodos tradicionais. Além disso, reduzem a subjetividade das avaliações visuais e favorecem a tomada de decisões em fases precoces do desenvolvimento das aves.

Diante desse contexto, este trabalho tem como objetivo desenvolver e aplicar modelos de inteligência artificial em (*Machine Learning*) para prever o peso e identificar o sexo de galinhas-d’angola, com base em medidas biométricas, contribuindo para um manejo mais eficiente e preciso na produção avícola.

2 Trabalhos Relacionados

3 Metodologia

Nesta seção, serão descritos os procedimentos adotados para o desenvolvimento dos modelos preditivos de peso corporal e sexo de galinhas-d’angola. A abordagem metodológica compreende a caracterização do conjunto de dados utilizado, o pré-processamento das medidas biométricas coletadas e a aplicação de técnicas de aprendizado de máquina para regressão e classificação. Foram conduzidos experimentos com configurações distintas de divisão dos dados e seleção de modelos, permitindo a comparação entre estratégias metodológicas e a identificação da abordagem mais adequada para cada tarefa.

3.1 Base de Dados

O estudo foi desenvolvido a partir de um conjunto de dados estruturado, composto por 235 espécimes de galinha-d’angola (*Numida meleagris*). A seleção das variáveis foi baseada na literatura sobre morfometria animal, priorizando indicadores relacionados ao crescimento e ao dimorfismo sexual.

As variáveis foram organizadas em três grupos principais:

Indicadores de porte: incluem o comprimento do corpo e da asa, que refletem o desenvolvimento somático geral das aves.

Variáveis osteométricas: correspondem ao comprimento do tarso e ao diâmetro da canela, sendo importantes para a avaliação da estrutura óssea e da sustentação corporal.

Atributos cefálicos e anexos: englobam o comprimento e a largura da cabeça, além das dimensões da barbela, características que podem estar associadas a diferenças entre os sexos.

Além dessas variáveis explicativas, o conjunto de dados inclui as variáveis-alvo utilizadas neste estudo: o peso vivo (em gramas), tratado como variável dependente nos modelos de regressão, e o sexo (macho/fêmea), utilizado como rótulo nos modelos de classificação supervisionada.

A Tabela 1 apresenta uma visão geral da distribuição das amostras ao longo das diferentes idades, bem como a quantidade de indivíduos por sexo e o peso médio observado em cada período. Observa-se que o conjunto de dados acompanha o desenvolvimento das aves desde o nascimento até 56 dias de idade, permitindo uma análise temporal do crescimento.

Tabela 1: Consolidação do dataset: amostras por idade, sexo e peso médio.

Idade (dias)	Machos (n)	Fêmeas (n)	Total (N)	Peso médio (g)
0	134	101	235	31,4
7	135	100	235	82,1
14	134	101	235	168,5
21	134	101	235	267,8
28	134	101	235	415,2
35	134	101	235	572,4
42	134	101	235	814,9
49	134	101	235	1012,3
56	118	82	200	1185,6
Total geral	1.190	890	2.080	—

3.2 Pré-Processamento dos Dados

Nesta etapa, realizei o preparo necessário para que os dados estivessem prontos para os algoritmos. Isso incluiu uma limpeza cuidadosa para remover possíveis erros de registro ou dados faltantes que pudessem comprometer os resultados.

Além disso, apliquei a padronização das variáveis biométricas. Esse passo foi fundamental para que medidas com escalas diferentes (como o comprimento da asa em centímetros e o peso em gramas) não confundissem os modelos, garantindo que todas as variáveis tivessem a mesma importância durante o treinamento. Também foi aqui que defini a estratégia de divisão do conjunto de dados para os testes de validação.

3.3 Modelagem Preditiva

Para atingir os objetivos deste trabalho, decidi utilizar três algoritmos de aprendizado de máquina que são referência na literatura para dados estruturados: XGBoost, SVM e Random Forest. A ideia aqui foi testar diferentes abordagens — desde modelos baseados em árvores até separação por hiperplanos — para ver qual deles se adaptava melhor às características biométricas das galinhas-d'angola, tanto para a parte de peso (regressão) quanto para o sexo (classificação). Antes de rodar os modelos, os dados passaram por um pré-processamento necessário. Isso incluiu a limpeza de possíveis erros de registro e a padronização das variáveis, para que medidas com escalas diferentes não confundissem os algoritmos. Também utilizei técnicas de busca de hiperparâmetros para ajustar os "ponteiros" de cada modelo, focando em evitar que eles ficassem viciados nos dados de treino (overfitting) e conseguissem performar bem com novos dados.

3.3.1 XGBoost

Escolhi o XGBoost por ele ser um dos algoritmos de boosting mais eficientes hoje em dia. Ele trabalha de forma sequencial, onde cada nova árvore tenta corrigir os erros deixados pelas anteriores. No meu caso, isso é interessante para a predição do peso corporal, já que o modelo consegue ir refinando a estimativa a cada iteração até chegar em um erro menor [3].

3.3.2 SVM (Support Vector Machine)

O SVM foi incluído por ser muito forte em problemas onde precisamos separar bem as classes, como é o caso da identificação do sexo das aves. Ele tenta encontrar o melhor "espaço" possível entre os dados de machos e fêmeas. Usei funções de kernel para que o algoritmo conseguisse enxergar padrões que não são lineares, o que ajuda muito quando as medidas físicas dos animais são muito próximas entre si [4].

3.3.3 Random Forest

Por fim, o Random Forest foi utilizado por ser um modelo de conjunto (ensemble) muito robusto. Como ele cria várias árvores de decisão de forma aleatória e combina os resultados, ele acaba sendo mais estável e menos sensível a ruídos ou pequenas falhas nas medições que possam ter ocorrido durante a coleta de dados [5].

4 Resultados

Nesta seção são apresentados os resultados obtidos com os modelos de aprendizado de máquina desenvolvidos para a predição do peso corporal e do sexo das galinhas-d'angola. Os experimentos foram conduzidos por faixa etária, abrangendo animais de 0 a 115 dias de vida. Para a predição de peso, foi empregado o modelo XGBoost Regressor, cujo desempenho é avaliado por meio das métricas R^2 , RMSE, MAE e erro relativo percentual. Para a classificação do sexo, utilizou-se o modelo Support Vector Machine (SVM), avaliado por acurácia, F1-Score e validação cruzada estratificada. Os resultados são discutidos considerando as particularidades de cada fase de crescimento das aves.

4.1 Experimento 1

Neste experimento, foram desenvolvidos e avaliados modelos de aprendizado de máquina para a predição do peso corporal e do sexo de galinhas-d'angola, com base em medidas biométricas coletadas em dez faixas etárias distintas (0, 7, 14, 21, 28, 52, 66, 80, 101 e 115 dias). Para a regressão, utilizou-se o modelo XGBoost; para a classificação do sexo, o Support Vector Machine (SVM). Ambos os modelos foram treinados individualmente por faixa etária, com busca de hiperparâmetros via *RandomizedSearchCV* e validação cruzada.

4.1.1 Predição de Peso Corporal com XGBoost

O modelo XGBoost foi treinado individualmente para cada faixa etária, utilizando os respectivos arquivos *dataset_idade_X.csv* (0, 7, 14, 21, 28, 52, 66, 80, 101 e 115 dias). A busca de hiperparâmetros foi realizada por *RandomizedSearchCV* com validação cruzada de 5 *folds*, em 10 rodadas com 10 iterações cada (100 configurações por modelo). Os preditores incluíram medidas morfométricas: circunferência abdominal (CIRCFABDOM), dorso, canela, asa, coxa, bico, circunferência de cabeça (CIRCFABECA), pescoço e sobrecoxa, e para animais com idade superior

a zero dias, o peso registrado na mensuração anterior (PESO_ANTERIOR). Foram geradas predições para 2.044 registros de 469 animais distintos.

Desempenho por Faixa Etária

A Tabela 2 consolida as métricas obtidas por faixa etária. O R^2_{CV} representa o coeficiente de determinação médio da validação cruzada interna, estimativa de generalização, enquanto R^2 , RMSE e MAE foram calculados sobre o conjunto completo de cada *dataset*. O erro relativo percentual (%MAE) foi calculado em relação ao peso médio predito de cada faixa.

Tabela 2: Desempenho do XGBoost na predição de peso corporal por faixa etária. N: animais com predição válida; R^2_{CV} : validação cruzada 5-*folds*; RMSE: raiz do erro quadrático médio; MAE: erro médio absoluto; Err. Máx.: maior erro absoluto registrado; %MAE: erro relativo ao peso médio.

Idade	N	R^2_{CV}	R^2	RMSE (g)	MAE (g)	Err. Máx. (g)	%MAE	PESO_ANT.
0	230	0,0613	0,2356	3,41	2,37	27,14	7,4%	Não
7	229	0,2798	0,5087	7,86	6,09	32,66	7,3%	Sim
14	223	0,4175	0,5549	18,00	12,82	94,59	7,7%	Sim
21	217	-0,0537	0,1327	52,62	41,06	235,46	15,3%	Sim
28	215	0,0593	0,1623	78,59	63,38	291,47	15,8%	Sim
52	223	0,6043	0,8681	79,22	47,52	550,05	6,1%	Sim
66	222	0,8166	0,9146	51,30	37,37	258,02	3,8%	Sim
80	211	0,4137	0,5154	128,30	76,94	1043,48	6,5%	Sim
101	116	0,4848	0,7942	70,48	47,61	298,88	3,7%	Sim
115	150	0,3983	0,6604	103,67	77,89	319,95	5,4%	Sim
Global (todas idades)		-	0,9810	68,9	-	-	-	-

Análise por Fase de Crescimento

Com base nos resultados apresentados na Tabela 2 e na Figura 1, identificam-se três fases funcionalmente distintas quanto ao desempenho preditivo.

Fase inicial — eclosão ao início de crescimento (0–14 dias). Nas primeiras duas semanas de vida, o modelo operou com erros relativos homogêneos, entre 7,3% e 7,7%. Ao nascimento (0 dias), a ausência de PESO_ANTERIOR como preditor limitou o R^2_{CV} a 0,0613, pois as medidas morfométricas apresentam baixa variabilidade entre indivíduos nessa fase ($\bar{x} \approx 32$ g). Ainda assim, o MAE de 2,37 g e o erro máximo de 27,14 g são aceitáveis em contexto zootécnico. Com a introdução do PESO_ANTERIOR aos 7 e 14 dias, o R^2_{CV} subiu para 0,2798 e 0,4175, respectivamente, com RMSE de 7,86 g e 18,00 g.

Fase crítica — maior variabilidade de crescimento (21–28 dias).

Este intervalo representou o maior desafio preditivo do estudo. Aos 21 dias, o R^2_{CV} atingiu valor negativo ($-0,0537$), indicando que o modelo de validação cruzada não superou um preditor trivial baseado na média do grupo. O MAE elevou-se a 41,06 g (15,3% do peso médio) e o erro máximo alcançou 235,46 g. Aos 28 dias, o padrão se manteve: $R^2_{CV} = 0,0593$, $MAE = 63,38$ g (15,8%) e erro máximo de 291,47 g. Biologicamente, este período corresponde à fase de máxima aceleração e maior variabilidade individual de crescimento nas aves, na qual as medidas morfométricas pontuais perdem capacidade de capturar as diferenças interindividuais de ganho de peso.

Fase de estabilização e crescimento final (52–115 dias).

A partir dos 52 dias, o modelo recuperou substancialmente o desempenho, com erros relativos entre 3,7% e 6,5%. O melhor resultado individual foi obtido aos 66 dias ($R^2_{CV} = 0,8166$; $R^2 = 0,9146$; $RMSE = 51,30$ g; $MAE = 37,37$ g; $\%MAE = 3,8\%$), fase associada à estabilização relativa das taxas de crescimento. Aos 52 dias, o desempenho também foi expressivo ($R^2_{CV} = 0,6043$; $MAE = 47,52$ g), e aos 101 dias o modelo registrou o segundo melhor erro relativo do estudo ($MAE = 47,61$ g; $\%MAE = 3,7\%$). Aos 80 e 115 dias, embora os MAE absolutos tenham sido maiores (76,94 g e 77,89 g, respectivamente), os erros relativos permaneceram abaixo de 7%. Destaca-se o erro máximo de 1.043,48 g registrado aos 80 dias, associado ao menos um animal morfometricamente atípico no conjunto de dados.

O R^2 global de 0,9810 e o RMSE de 68,9 g, calculados sobre todas as faixas etárias em conjunto (Figura 1B), refletem a elevada cobertura preditiva do sistema ao longo de toda a curva de crescimento — de ≈ 32 g (eclosão) a ≈ 1.447 g (115 dias). Ressalva-se que parte da magnitude deste R^2 global decorre da grande amplitude de peso entre faixas etárias distintas; o R^2_{CV} por idade constitui, portanto, a estimativa mais fidedigna da capacidade preditiva de cada modelo.

Importância das Variáveis Predictoras

A Figura 2 exibe a importância relativa de cada preditor por faixa etária. Três padrões principais foram observados.

Aos **0 dias**, sem a disponibilidade de PESO_ANTERIOR, a **canela** ($\approx 0,16$) e a **circunferência abdominal** ($\approx 0,14$) foram os preditores dominantes, seguidas pela **circunferência de cabeça** ($\approx 0,12$). A canela, por refletir o desenvolvimento esquelético apendicular, constitui um indicador, indireto, razoável do tamanho corporal ao nascimento.

Aos **7 dias**, a **circunferência abdominal** manteve-se como preditor principal ($\approx 0,18$), seguida pelo **dorso** ($\approx 0,15$), com PESO_ANTERIOR ainda em posição




Figura 1: Desempenho do XGBoost por faixa etária. **(A)** R^2 por idade (barra vermelha: melhor desempenho, $R^2 = 0,9146$ aos 66 dias). **(B)** Dispersão entre peso real e peso predito em todas as faixas etárias, colorida por idade ($R^2 = 0,9810$; RMSE = 68,9 g). **(C)** Erro Médio Absoluto (MAE) por faixa etária. **(D)** Análise de resíduos.

secundária ($\approx 0,12$). Este resultado sugere que, na primeira semana de vida, o desenvolvimento morfométrico é mais informativo do que o peso ao eclodir para prever o ganho de peso subsequente.

A partir dos **14 dias**, o PESO_ANTERIOR emergiu como preditor dominante e sua importância aumentou progressivamente: $\approx 0,25$ (14 dias), $\approx 0,40$ (52 dias) e $0,30-0,35$ nas fases finais (80, 101 e 115 dias). Este padrão confirma a consistência das trajetórias individuais de crescimento: o histórico ponderal é o melhor indicador do peso subsequente. Entre as medidas morfométricas, a **circunferência abdominal** destacou-se sistematicamente como a de maior importância relativa em todas as faixas etárias com PESO_ANTERIOR disponível, seguida pelo **dorso** e pelo **bico**.




Figura 2: Importância relativa das variáveis preditoras por faixa etária (XG-Boost). Aos 0 dias, apenas medidas morfométricas estão disponíveis; canela e circunferência abdominal dominam. A partir de 14 dias, o PESO_ANTERIOR passa a ser o preditor principal, atingindo importância máxima de $\approx 0,40$ aos 52 dias.

Análise de Resíduos

A análise de resíduos (Figura 1D) indica distribuição aproximadamente simétrica em torno de zero nas faixas de 0 a 14 dias, com baixa dispersão, coerente com os menores RMSE e MAE absolutos registrados nessas idades. A partir dos 52 dias, observa-se crescente heteroscedasticidade: a dispersão dos resíduos amplia-se com o aumento do peso predito, padrão típico em modelos de crescimento com alta

variabilidade individual. Resíduos negativos de grande magnitude foram identificados em aves específicas nas faixas de 52 a 80 dias, sugerindo superestimativa para indivíduos com desenvolvimento tardio. O erro máximo de 1.043,48 g aos 80 dias evidencia a presença de ao menos um animal morfometricamente atípico, cuja influência não foi suficientemente capturada pelo modelo.

4.1.2 Predição de Sexo com SVM

O modelo Support Vector Machine (SVM) foi treinado individualmente para cada faixa etária com o objetivo de classificar o sexo das aves (Macho/Fêmea) a partir de seis variáveis morfométricas: peso corporal, circunferência abdominal, dorso, canela, asa e coxa. A busca de hiperparâmetros foi conduzida por *Randomized-SearchCV* com validação cruzada estratificada (*StratifiedKFold*, 5 folds), em 20 rodadas de 5 iterações cada, com padronização das variáveis integrada ao modelo em um *Pipeline*. Foram geradas 2.052 predições para 472 animais.

A Tabela 3 sintetiza os resultados por faixa etária. O $F1_{CV}$ manteve-se entre 0,70 e 0,75 em todas as idades, valor próximo ao *baseline* de um classificador trivial que prediz sempre a classe majoritária ($\approx 58\%$ Machos), indicando que as medidas morfométricas, isoladamente, apresentaram baixa capacidade discriminatória entre os sexos na maior parte das faixas.

Tabela 3: Desempenho do SVM na predição de sexo por faixa etária. $F1_{CV}$: validação cruzada estratificada; Acc: acurácia; F1: F1-Score sobre o conjunto de dados completo.

Idade	N	$F1_{CV}$	F1	Acc	Rec (Macho)	Kernel
0	229	0,7348	0,7348	0,5808	1,0000	poly
7	232	0,7432	0,7642	0,6595	0,9412	rbf
14	225	0,7495	0,7472	0,6000	1,0000	poly
21	220	0,7184	1,0000	1,0000	1,0000	rbf
28	220	0,7436	0,7414	0,5909	1,0000	poly
52	224	0,7424	0,0000	0,4152	0,0000	rbf
66	222	0,7457	0,7479	0,5991	1,0000	poly
80	211	0,7485	0,7485	0,6019	1,0000	poly
101	116	0,6987	0,7619	0,7414	0,7742	rbf
115	151	0,7480	1,0000	1,0000	1,0000	rbf

Como evidenciado pelas matrizes de confusão (Figura 3), na maioria das faixas etárias o modelo tendeu a classificar todos os animais como Macho, refletindo o desequilíbrio de classes e a baixa separabilidade morfométrica entre os sexos

nessas idades. Exceções notáveis foram os 52 dias — onde o modelo classificou todos como Fêmea, com $F1 = 0,00$ — e as faixas de 21 e 115 dias, nas quais se observou acurácia perfeita (100%), resultado atribuído ao sobreajuste do modelo aos dados de treinamento, não refletindo capacidade real de generalização. O único resultado genuinamente equilibrado foi obtido aos 101 dias, com acurácia de 74% e discriminação razoável entre as classes (recall Fêmea = 70%; recall Macho = 77%), sugerindo que o dimorfismo sexual começa a se expressar nas medidas morfométricas de forma mais consistente nessa fase (Figura 4).




Figura 3: Matrizes de confusão do SVM por faixa etária. O padrão predominante de classificação exclusiva como Macho é visível em 0, 14, 28, 66 e 80 dias. Aos 52 dias ocorre o comportamento inverso (todos Fêmea). O resultado mais equilibrado é observado aos 101 dias.

4.2 Experimento 2

Neste experimento foi utilizado o conjunto de dados completo, realizando-se uma separação manual de 20% dos dados para teste, garantindo o balanceamento entre machos e fêmeas. Além disso, foram avaliados múltiplos algoritmos para a tarefa de classificação do sexo, bem como analisada a importância das variáveis no modelo




Figura 4: Comparação de Acurácia, F1-Score e $F1_{CV}$ entre faixas etárias. O $F1_{CV}$ uniforme de $\approx 0,73$ evidencia comportamento próximo ao classificador de maioria na maioria das idades, com exceção da faixa dos 101 dias.

XGBoost. Para as tarefas de regressão e classificação finais, utilizou-se o XGBoost.

4.2.1 Classificação do Sexo — Comparação de Modelos

Inicialmente, foram avaliados diferentes algoritmos de classificação visando comparar seus desempenhos na predição do sexo das aves. Entre os modelos testados, destacaram-se XGBoost, LightGBM e KNN, que apresentaram os melhores resultados em termos de F1-Score (Figura 5).

O modelo XGBoost Classifier apresentou o melhor desempenho geral, com F1-Score de aproximadamente 0,744 no conjunto de teste, além de recall elevado (0,974). No entanto, esse alto recall indica que o modelo tende a classificar corretamente a maioria de uma classe específica, possivelmente às custas de erros na outra classe.

A matriz de confusão do melhor modelo evidencia um forte desbalanceamento nas predições: a grande maioria das fêmeas foi incorretamente classificada como machos (172 erros contra apenas 14 acertos), enquanto os machos foram corretamente classificados em sua maioria (260 acertos).

4.2.2 Predição do Peso Corporal — XGBoost

Para a predição do peso corporal, foi utilizado um modelo único de XGBoost treinado sobre todas as idades. O modelo apresentou bom desempenho global, com $R^2 = 0,9410$ e $RMSE = 113,4$ g no conjunto de teste (Figura 6).

A análise por idade revelou comportamento bastante heterogêneo. A idade de 0 dias apresentou desempenho extremamente baixo (R^2 negativo), indicando que o modelo não consegue capturar padrões relevantes nessa fase inicial.

O desempenho obtido é comparável ao reportado por [6] em ovelhas Norduz




Figura 5: Comparação entre modelos para classificação de sexo: F1-Score, métricas do melhor modelo e análise por idade.




Figura 6: Desempenho do XGBoost: (1) R^2 por idade, (2) valores reais vs. preditos, (3) MAE por idade e (4) análise de resíduos.

(RMSE = 4,47) e por [7] em frangos Ross 308. A relevância da circunferência abdominal como principal preditor confirma os resultados de [8], que identificou o perímetro torácico como melhor preditor isolado ($R^2 = 0,558$) em galinhas-d'angola.

4.2.3 Importância das Variáveis — XGBoost

A análise da importância das *features* no modelo revelou que a circunferência abdominal (CIRCFABDOM) é, de forma destacada, a variável mais relevante para a predição do peso corporal, seguida por dorso, idade e circunferência da cabeça (Figura 7).




Figura 7: Importância das variáveis no modelo XGBoost.

4.2.4 Considerações do Experimento 2

Os resultados do Experimento 2 indicam que, embora o uso do conjunto de dados completo e balanceado melhore a consistência metodológica, ainda persistem limitações importantes. Na classificação do sexo, mesmo os melhores modelos apresentaram viés significativo, com dificuldade em identificar corretamente fêmeas.

Na predição do peso corporal, o modelo XGBoost apresentou bom desempenho global, porém inferior ao Experimento 1. Por outro lado, essa abordagem resulta

em um modelo mais interpretável e mais robusto. De forma geral, os resultados sugerem um compromisso entre desempenho e capacidade de generalização.

4.3 Experimento 3

Neste experimento, foi realizada uma comparação sistemática entre múltiplos algoritmos de aprendizado de máquina para ambas as tarefas: predição de peso corporal e classificação do sexo, utilizando o conjunto de dados completo, com separação por animal entre treino e teste. O objetivo foi identificar qual família de algoritmos apresenta melhor desempenho no contexto biométrico das galinhas-d’angola ao longo de todo o ciclo de crescimento, sem restrição a uma faixa etária específica.

Em ambas as tarefas, o critério de isolamento por animal foi mantido: 20% dos animais foram reservados para teste (`random_state=42`), de forma que nenhuma observação de um mesmo indivíduo ocorra simultaneamente em treino e teste. A busca de hiperparâmetros foi conduzida por *RandomizedSearchCV* em todos os modelos.

4.3.1 Predição de Peso Corporal — Comparação de Modelos

Dez algoritmos de regressão foram avaliados: Random Forest, Extra Trees, Gradient Boosting, XGBoost, LightGBM, KNN, Ridge, Lasso, ElasticNet e SVR. Os preditores utilizados foram as treze variáveis morfométricas disponíveis no conjunto de dados: bico, circunferência de cabeça (CIRCFCABECA), pescoço, asa, tulipa, dorso, ventre, circunferência abdominal (CIRCFABDOM), sobrecoxa, coxa, canela, unhamaior e PESO, acrescidas da idade (IDADE). Diferentemente do Experimento 1, o peso registrado na mensuração anterior (PESO_ANTERIOR) não foi utilizado como preditor, pois o modelo opera com dados transversais de todo o ciclo de crescimento, sem acesso ao histórico ponderal individual.

A validação cruzada foi conduzida com *KFold* (5 *folds*), adotando o R^2 como critério de otimização. Para mitigar o desbalanceamento amostral entre faixas etárias, o SMOTE foi aplicado ao conjunto de treino antes do ajuste: o alvo (PESO) foi discretizado em cinco quantis e utilizado como rótulo auxiliar, de modo que as variáveis preditoras e o peso foram interpolados conjuntamente na síntese de amostras.

A Tabela 4 apresenta o R^2 de teste de todos os modelos avaliados. O melhor resultado individual foi obtido pelo **Random Forest** ($R_{CV}^2 = 0,9447$; $R_{test}^2 = 0,9453$; RMSE = 107,1 g; MAE = 68,6 g), seguido de perto por Extra Trees e Gradient Boosting.

Tabela 4: Comparação de algoritmos de regressão para predição de peso corporal.

Rank	Modelo	R^2 Teste
1	Random Forest	0,9453
2	Extra Trees	0,9449
3	Gradient Boosting	0,9419
4	XGBoost	0,9418
5	LightGBM	0,9399
6	KNN	0,9393
7	Lasso	0,9269
8	Ridge	0,9263
9	ElasticNet	0,9235
10	SVR	0,9162

O desempenho global foi elevado e homogêneo entre todos os algoritmos: o intervalo de R^2 variou de 0,9162 (SVR) a 0,9453 (Random Forest), diferença de apenas 2,9 pontos percentuais. Os métodos de *ensemble* baseados em árvores: Random Forest, Extra Trees, Gradient Boosting, XGBoost e LightGBM, concentraram-se entre as cinco primeiras posições, com $R^2 \geq 0,9399$. Os modelos lineares regularizados (Lasso, Ridge, ElasticNet) e o SVR situaram-se nas últimas posições, porém ainda com $R^2 > 0,91$, evidenciando forte componente linear na relação entre as medidas morfométricas e o peso.

Contudo, a análise por faixa etária para os três melhores modelos (Figura 8D) revela comportamento marcadamente heterogêneo: nas idades de 0 e 7 dias, o R^2 intra-etário colapsa para valores próximos ou negativos, indicando que o modelo não supera um preditor trivial baseado na média do grupo nessas fases. O R^2 global elevado decorre, portanto, da dominância da variável **IDADE** como preditor, o modelo captura principalmente a progressão ponderal entre faixas etárias, e não as diferenças individuais dentro de cada faixa. Esta limitação estrutural é análoga à observada no Experimento 2 e reforça que a estratificação por idade, adotada no Experimento 1, é essencial para estimativas fidedignas da capacidade preditiva real.

4.3.2 Classificação do Sexo — Comparação de Modelos

Oito algoritmos de classificação foram avaliados: Gradient Boosting, Random Forest, Extra Trees, XGBoost, LightGBM, SVM, KNN e Regressão Logística. Os preditores incluíram as treze variáveis morfométricas e a idade (**IDADE**), totalizando



Figura 8: Comparação de algoritmos de regressão para predição de peso corporal. **(A)** R^2 por modelo (CV e Teste). **(B)** MAE por modelo. **(C)** Valores reais *vs.* preditos pelo melhor modelo (Random Forest; $R^2 = 0,9453$). **(D)** R^2 por faixa etária para os três melhores modelos.

catorze variáveis. A validação cruzada foi conduzida com *StratifiedKFold* (5 *folds*), adotando o F1-Score como critério de otimização, adequado ao desbalanceamento de classes. O SMOTE foi incorporado diretamente ao *pipeline* de cada modelo, sendo aplicado exclusivamente dentro de cada *fold* de treinamento para prevenir vazamento de dados.

A Tabela 5 apresenta o F1-Score de teste de todos os modelos. O melhor resultado foi obtido pelo **Gradient Boosting**, com $F1_{CV} = 0,6403$, $F1$ teste = 0,6546, acurácia = 0,5784, precisão $\approx 0,633$ e *recall* $\approx 0,678$.

Tabela 5: Comparação de algoritmos de classificação para predição de sexo

Rank	Modelo	F1 Teste
1	Gradient Boosting	0,6546
2	Random Forest	0,6448
3	Extra Trees	0,6312
4	XGBoost	0,6250
5	LightGBM	0,6160
6	SVM	0,5896
7	KNN	0,5820
8	Regressão Logística	0,5350

Um resultado particularmente revelador é que a acurácia do melhor modelo(0,5784) ficou abaixo da acurácia do classificador de maioria (*baseline* = 0,5894), indicando que nenhum algoritmo superou a estratégia trivial de predizer sempre a classe predominante em termos de acerto global. O F1-Score superior ao *baseline* reflete que o SMOTE induziu uma redistribuição das predições entre as classes, elevando o *recall* da classe minoritária às custas da acurácia bruta, sem que isso se traduzisse em ganho real de discriminação.

A matriz de confusão do melhor modelo (Figura 9C) evidencia o padrão já observado nos experimentos anteriores: elevada taxa de erros na classificação de fêmeas, com a maioria dos indivíduos dessa classe sendo incorretamente classificada como macho. A análise por faixa etária (Figura 9D) revela acentuada instabilidade: a acurácia dos três melhores modelos oscila entre 0,4 e 0,9 ao longo das dez idades, sem padrão consistente de melhora, resultado análogo ao observado com o SVM no Experimento 1.

Considerações do Experimento 3

O Experimento 3 corrobora e expande os achados dos experimentos anteriores. Na predição de peso, todos os dez algoritmos avaliados atingiram R^2 global superior




Figura 9: Comparação de algoritmos de classificação para predição de sexo. **(A)** F1-Score por modelo (CV e Teste). **(B)** Métricas do melhor modelo (Gradient Boosting). **(C)** Matriz de confusão do melhor modelo. **(D)** Acurácia por faixa etária para os três melhores modelos.

a 0,91, com os métodos de *ensemble* baseados em árvores liderando o ranking. Todavia, o R^2 global é substancialmente inflado pela amplitude ponderal entre faixas etárias, e o desempenho intra-etário é consideravelmente inferior, em especial nos primeiros dias de vida, padrão consistente com os Experimentos 1 e 2, que reforça a superioridade da abordagem estratificada por idade para estimativas preditivas precisas.

Na classificação do sexo, a avaliação de oito algoritmos distintos confirma que nenhuma abordagem consegue superar o *baseline* de maioria em acurácia, independentemente do algoritmo empregado. Os resultados convergem para a conclusão de que as medidas morfométricas disponíveis não carregam sinal discriminatório robusto entre os sexos na maior parte do ciclo de crescimento das galinhas-d'angola, limitação que não é contornada pela escolha do algoritmo, pelo balanceamento via SMOTE nem pela inclusão do peso corporal como preditor.

4.4 Experimento 4

Esse experimento parte de uma ideia diferente dos anteriores. Em vez de usar as medidas do corpo da ave, ele tenta descobrir o sexo olhando para como o peso da ave evolui ao longo do tempo. A pergunta que o algoritmo busca responder é: machos e fêmeas crescem de formas distintas o suficiente para que essa diferença, sozinha, permita classificar o sexo?

Para responder isso, o código organiza o histórico de cada ave em ordem de idade e cria novas variáveis que descrevem o comportamento da curva de crescimento de cada animal. Essas variáveis usam apenas dados passados da própria ave, evitando vazamento de informação do futuro para o presente. A Tabela 6 resume cada uma.

Depois de criar essas variáveis, o experimento testa 8 algoritmos de classificação (XGBoost, LightGBM, Random Forest, Extra Trees, Gradient Boosting, SVM, KNN e Regressão Logística), todos com busca de hiperparâmetros via RandomizedSearchCV, balanceamento por SMOTE e separação por animal, ou seja, uma mesma ave nunca aparece ao mesmo tempo em treino e teste.

4.4.1 Resultados

Antes da classificação, o experimento avalia a qualidade da previsão de peso pela média móvel. Os números mostram um erro médio absoluto de 293,74 g e um erro quadrático médio de 329,53 g, valores altos diante da escala de pesos do conjunto, que vai de 32 g a quase 1500 g. Isso já indica que a curva de crescimento é bastante variável dentro do mesmo animal.

A comparação dos modelos é apresentada na Tabela 7.

Tabela 6: Variáveis criadas a partir da relação entre idade e peso de cada ave.

Variável	O que representa
IDADE	Idade da ave em dias.
PESO	Peso atual da ave em gramas.
PESO_PRED_MA	Média móvel dos 3 últimos pesos, usada como previsão do próximo peso.
PESO_RESID	Diferença entre o peso real e o peso previsto, mostra o quanto a ave fugiu da própria tendência.
GANHO_PESO	Quanto a ave engordou desde a medição anterior.
TAXA_CRESC	Velocidade de crescimento, calculada como GANHO_PESO dividido pela variação de idade.
TAXA_CRESC_MA	Média móvel da taxa de crescimento nas 3 últimas medições.
PESO_ACUM_MA	Média acumulada de todos os pesos passados da ave, que funciona como linha de base do animal.
SLOPE_IA	Inclinação da reta de regressão linear entre PESO e IDADE no histórico da ave.

O melhor modelo foi o *Extra Trees*, com F1 de 0,564 no teste e acurácia de 0,558. A linha de base, que consiste em sempre prever a classe majoritária, atinge 0,442 de acurácia, então o modelo fica cerca de 11 pontos percentuais acima desse piso.

Olhando a matriz de confusão do *Extra Trees*, o modelo acertou 103 fêmeas e 108 machos, mas confundiu 108 fêmeas como machos. A revocação (*recall*) alta (0,647) com precisão baixa (0,500) mostra que ele tende a chutar mais para a classe positiva, errando bastante quando faz isso.

O gráfico das curvas de crescimento médio por sexo, gerado no painel inferior direito da Figura 10, deixa claro o motivo dessa dificuldade. As duas curvas, de machos e fêmeas, estão praticamente sobrepostas em todas as idades. Em outras palavras, na média a velocidade e o formato do crescimento são quase idênticos entre os sexos, então as variáveis derivadas dessa curva não conseguem separar bem as classes.

4.4.2 Considerações Do Experimento 4

O experimento mostra que mesmo trocando o tipo de informação usada, abandonando as medidas do corpo e olhando só para a relação entre idade e peso,




Figura 10: Resultados do Experimento 4: comparação dos modelos, métricas do melhor modelo, matriz de confusão e curvas de crescimento por sexo.

Tabela 7: Comparação dos modelos de classificação no Experimento 4, ordenados por F1 no teste.

Modelo	F1 Validação	F1 Teste	Acurácia
Extra Trees	0,633	0,564	0,558
XGBoost	0,594	0,544	0,549
Random Forest	0,610	0,532	0,547
Gradient Boosting	0,613	0,527	0,549
LightGBM	0,616	0,510	0,531
SVM	0,533	0,489	0,503
KNN	0,489	0,487	0,509
Regressão Logística	0,494	0,427	0,475

ainda não é possível classificar o sexo das aves com qualidade. O modelo ganha algum sinal sobre a baseline, mas longe de um resultado prático, e ele só funciona um pouco porque captura pequenas diferenças individuais, não porque exista um padrão consistente de crescimento por sexo.

Esse resultado reforça a conclusão central da pesquisa: a galinha d’Angola é uma espécie monomórfica, ou seja, machos e fêmeas se desenvolvem com tamanhos e curvas de crescimento muito parecidos, e por isso variáveis morfométricas, sozinhas ou combinadas em features de crescimento, não bastam para distinguir o sexo de forma confiável.

5 Conclusão

Referências

- [1] Matheus Brasileiro Campos. Arcabouço para o desenvolvimento de aplicações de monitoramento de praticantes de exercícios físicos, 2015. Dissertação (Mestrado em Ciência da Computação) – Universidade Federal de Campina Grande. Acesso em: 10 abr. 2026.
- [2] Flávia Bottino, Silvana Martinez Baraldi Artoni, Daniela Oliveira, Vanessa Sobue Franzo, Maria Rita Pacheco, Antonio Marcos Orsi, and Lizandra Amoro. Influência do dimorfismo sexual sobre a morfologia da siringe de galinha d’angola (numida meleagris). *Ciência Rural*, 36(5):1424–1428, 2006. Acesso em: 20 abr. 2026.

- [3] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016.
- [4] Corinna Cortes and Vladimir Vapnik. Support-vector networks. *Machine Learning*, 20(3):273–297, 1995.
- [5] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.
- [6] Onur Çakmakçı. Prediction of body weight from body measurements in norduz sheep using machine learning algorithms. *Turkish Journal of Agriculture and Forestry*, 2022.
- [7] Bila. 2025.
- [8] D. M. Ogah. Canonical analysis of body weight and biometric traits of helmeted guinea fowl. *Slovak Journal of Animal Science*, 45(1):1–7, 2012.