

Desenvolvimento de uma Ferramenta de Modelagem Preditiva para Identificação de Sexo e Estimativa de Peso em Galinhas

João Vitor Santana Lima¹

¹Programa de Iniciação Científica ICV/UFPI

Universidade Federal do Piauí (UFPI)

Orientadora: Alcilene Dalília de Sousa

j.v.s.12009@gmail.com

1. Introdução

Com o crescimento da avicultura e a busca por maior eficiência nos sistemas de criação, torna-se cada vez mais necessário adotar ferramentas tecnológicas que auxiliem no manejo das aves. A obtenção rápida, prática e confiável de informações essenciais sobre cada indivíduo, como peso corporal e sexo, contribui para um controle mais preciso do plantel e para a melhoria dos índices produtivos.

A galinha-d'angola (*Numida meleagris*), pertencente à ordem dos *Galliformes* e à família *Numididae*, é uma ave originária da África e foi introduzida no Brasil pelos colonizadores portugueses, provenientes da África Ocidental. No país, também é conhecida popularmente como guiné, galinha-do-mato, capote, capota, pintada, picote (na Amazônia) ou tô-fraca (TARGINO, 2015). Trata-se de uma espécie rústica, com boa adaptabilidade a diferentes condições climáticas, o que a torna relevante para a avicultura familiar e de pequena escala em diversas regiões brasileiras (OGAH et al., 2022).

Apesar de sua importância, a criação de galinhas-d'angola ainda carece de tecnologias voltadas ao manejo produtivo. Nas fases iniciais de desenvolvimento, essas aves apresentam grande semelhança morfológica entre machos e fêmeas, o que dificulta a identificação do sexo por meio da observação visual. Estima-se que pelo menos metade das espécies de aves existentes no mundo não possua dimorfismo sexual evidente, sendo essa diferenciação geralmente sutil e manifestada somente a partir da maturidade sexual (VIEIRA et al., 2009). No caso específico da galinha-d'angola, a diferenciação entre os sexos pode ser feita pela vocalização, onde as fêmeas emitem o característico som “tô-fraco”, enquanto os machos produzem arrulhos e cacarejos (BOTTINO et al., 2006). Essa limitação compromete decisões de manejo, como a formação de lotes, a seleção de reprodutores e o direcionamento adequado da produção.

Nesse contexto, o uso de técnicas de inteligência artificial, como as redes neurais artificiais, surge como uma alternativa promissora para a predição do peso corporal e a identificação do sexo de galinhas-d'angola a partir de medidas biométricas. Na avicultura, as redes neurais artificiais já demonstraram elevada capacidade na predição de parâmetros de desempenho produtivo, superando modelos estatísticos convencionais na modelagem de relações não lineares entre variáveis (SALLE et al., 2001). Esses modelos possibilitam estimativas mais precisas e ágeis em comparação aos métodos tradicionais, reduzem a subjetividade inerente às avaliações visuais e favorecem a tomada de decisões em fases precoces do desenvolvimento das aves.

Apesar da relevância da espécie, ainda não existem modelos robustos que permi-

tam simultaneamente a predição de peso e classificação de sexo em galinhas-d'angola a partir de medidas morfométricas. Diante do exposto, o presente trabalho tem como objetivo desenvolver e avaliar modelos de aprendizagem de máquina para predição do peso corporal e classificação do sexo de galinhas-d'angola a partir de suas medidas corporais.

2. Revisão de Literatura

A predição de características produtivas a partir de medidas corporais em aves e outras espécies de interesse zootécnico tem sido amplamente investigada nas últimas décadas. Com o avanço das técnicas de inteligência artificial e aprendizado de máquina, novos métodos vêm sendo propostos como alternativas aos modelos estatísticos tradicionais, oferecendo maior capacidade de captura de relações não lineares entre variáveis morfométricas e características de interesse econômico. A presente revisão reúne os principais estudos que fundamentam esta pesquisa, abrangendo trabalhos sobre a galinha-d'angola, predição de peso corporal em aves e outras espécies, e a aplicação de diferentes técnicas computacionais na modelagem preditiva.

(OGAH et al., 2012) avaliou a relação entre medidas corporais e características de carcaça em galinhas-d'angola indígenas da Nigéria, utilizando 28 aves adultas de ambos os sexos. Os resultados mostraram que o perímetro torácico foi o melhor preditor isolado do peso corporal ($R^2 = 0,558$), enquanto o peso corporal destacou-se como a variável mais importante na predição do peso de carcaça ($R^2 = 0,820$) e do peso do peito ($R^2 = 0,902$). O estudo demonstra que medidas lineares simples podem ser utilizadas com razoável precisão para estimar o peso vivo e características de carcaça em galinhas-d'angola.

(DZUNGWE et al., 2018) investigaram a relação entre peso corporal e medidas lineares em galinhas-d'angola francesas de corte, criadas em condições tropicais úmidas na Nigéria. Um total de 86 aves foi avaliado com 38 semanas de idade, mensurando-se comprimento da canela, comprimento da coxa, comprimento da quilha, perímetro torácico, comprimento corporal e comprimento da asa. As correlações entre peso corporal e medidas lineares foram positivas e significativas ($P < 0,01$). O comprimento da canela apresentou o maior coeficiente de determinação ($R^2 = 19,5\%$), indicando ser o melhor preditor do peso corporal nessa linhagem.

(PORTILLO-SALGADO et al., 2021) utilizaram regressão linear múltipla e análise de árvore de regressão (algoritmo CHAID) para prever o peso de ovos de galinhas-d'angola a partir de características externas. Foram avaliados 110 ovos de um lote com 23 semanas de idade. A área de superfície do ovo foi a variável preditora mais importante, explicando 72% da variação no peso do ovo por regressão linear e 74% pela árvore de regressão. Ambos os métodos estatísticos demonstraram precisão semelhante, confirmando que características externas dos ovos podem ser utilizadas de forma confiável para estimar seu peso.

(REIS et al., 2008) estudaram a predição do peso vivo a partir de medidas corporais em bovinos mestiços Holandês/Gir, utilizando dados de 483 vacas, 469 novilhas e 62 machos. Embora o estudo tenha sido conduzido com bovinos, a abordagem metodológica é relevante para o presente trabalho. O perímetro torácico apresentou a maior correlação com o peso corporal em todas as categorias (0,807 para vacas; 0,928 para machos; 0,942 para novilhas). Modelos polinomiais cúbicos proporcionam alta aderência, demonstrando que uma única medida corporal pode ser suficiente para estimativas precisas do peso.

(JAHAN et al., 2020) desenvolveram um modelo de rede neural artificial (RNA) do tipo perceptron multicamadas para prever o peso de abate de codornas japonesas com base no desempenho de crescimento inicial, sexo e peso do ovo. A melhor arquitetura de rede possuía 7 neurônios na camada de entrada, 11 na camada oculta e 1 na camada de saída. Os coeficientes de determinação obtidos foram $R^2 = 0,9404$, $0,9359$ e $0,9223$ para as fases de treinamento, validação e teste, respectivamente. A análise de sensibilidade revelou que o peso corporal aos 20 dias foi a variável de entrada mais importante, enquanto o sexo foi o segundo preditor mais relevante.

(CAKMAKÇI, 2022) comparou o desempenho preditivo de quatro algoritmos de aprendizado de máquina: *Random Forest* (RF), *Support Vector Machines* (SVM), *Classification and Regression Trees* (CART) e *Model Average Neural Networks* (MANN), para estimar o peso vivo de ovelhas Norduz a partir de medidas morfológicas. O algoritmo RF apresentou os menores valores de erro absoluto médio (MAE = 3,66), erro quadrático médio (RMSE = 4,47) e erro percentual absoluto médio (MAPE = 0,07) no conjunto de teste. O estudo utilizou o algoritmo Boruta para seleção de variáveis, identificando largura e profundidade torácica como os preditores mais importantes.

(BILA, 2025) empregou os algoritmos *MARS* (Multivariate Adaptive Regression Splines) e CART para prever o peso corporal de frangos Ross 308 a partir de medidas morfológicas. Foram utilizadas 120 aves (60 machos e 60 fêmeas) com cinco semanas de idade. O algoritmo CART superou o MARS em termos de coeficiente de correlação de Pearson, coeficiente de determinação e coeficiente de determinação ajustado, tanto para machos quanto para fêmeas. O comprimento corporal e o perímetro torácico foram identificados como as variáveis mais influentes na determinação do peso.

(UROOJ et al., 2023) propuseram um modelo ensemble de aprendizado de máquina combinando KNN, Random Forest, árvore de regressão e SVM para prever o peso corporal de frangos Ross 308 a partir de medidas morfométricas. Foram utilizados 500 registros de 100 aves (50 machos e 50 fêmeas) do 1º ao 29º dia de idade. O modelo ensemble superou todos os algoritmos individuais, alcançando $R^2_{adj} = 0,999$ e RMSE = 5,465 g no conjunto de teste. O comprimento da canela foi identificado como o preditor mais importante, respondendo por 28% da variação total.

(KÜÇÜKTOPÇU et al., 2026) avaliaram o potencial de cinco algoritmos de aprendizado de máquina supervisionado: RF, KNN, SVR, *XGBoost* e regressão linear múltipla, e análise de imagem digital para predição não invasiva do peso vivo em frangos *Anadolu-T*. Um total de 4200 registros foi coletado de 100 frangos ao longo de 42 dias. O algoritmo KNN alcançou a maior precisão ($R^2 = 0,982$, RMSE = 111,509 g), seguido pelo RF e *XGBoost*. Os modelos baseados em imagens digitais também apresentaram alta precisão ($R^2 = 0,989$), confirmando que a área de superfície projetada pode representar eficazmente o progresso do crescimento.

A Tabela 1 apresenta uma síntese comparativa dos estudos revisados, considerando os critérios que se relacionam diretamente com a presente pesquisa. Observa-se que, embora diversos trabalhos abordem a predição do peso corporal a partir de medidas lineares e utilizem técnicas de aprendizado de máquina, nenhum deles integra simultaneamente a galinha-d'angola como espécie-alvo, a predição de peso corporal e a classificação do sexo por meio de modelos computacionais. Dessa forma, este trabalho contribui ao in-

tegrar essas abordagens em um único modelo aplicado à espécie.

Tabela 1. Comparação dos estudos revisados segundo critérios da presente pesquisa.

Estudo	Galinha-d'angola	Predição de peso corporal	Classificação de sexo	Machine Learning	Regressão linear ou múltipla	Medidas corporais de entrada
Ogah (2012)	X	X			X	X
Dzungwe et al. (2018)	X	X			X	X
Portillo-Salgado et al. (2021)	X				X	X
Reis et al. (2020)		X			X	X
Jahan et al. (2020)		X	X	X		X
Çakmakçı (2022)		X		X		X
Bila (2025)		X		X		X
Urooj et al. (2023)		X		X		X
Küçüktopçu et al. (2026)		X		X	X	X
Presente estudo	X	X	X	X	X	X

3. Metodologia

Esta seção descreve os procedimentos metodológicos adotados no desenvolvimento da ferramenta de modelagem preditiva. Inicialmente, é apresentada a base de dados utilizada, com a descrição dos registros e das medidas corporais coletadas. Em seguida, são detalhadas as etapas de pré-processamento aplicadas aos dados, os algoritmos de aprendizado de máquina empregados nas tarefas de regressão e classificação e, por fim, as técnicas de validação e as métricas utilizadas para avaliar o desempenho dos modelos.

3.1. Base de dados

O dataset é composto por 2.299 registros referentes a 238 galinhas-d'angola, sendo 1.348 registros de machos e 949 de fêmeas. As medições foram realizadas em 12 idades distintas: 0, 7, 14, 21, 28, 35, 38, 52, 66, 80, 101 e 115 dias de vida, caracterizando um acompanhamento longitudinal do crescimento das aves.

Para cada ave, foram registradas 13 medidas corporais (em centímetros): comprimento do bico, circunferência da cabeça, comprimento do pescoço, comprimento da asa, comprimento da tulipa, comprimento do dorso, comprimento do ventre, circunferência abdominal, comprimento da sobrecoxa, comprimento da coxa, comprimento da canela e comprimento da unha maior, além do peso corporal (em gramas) e do sexo do animal. A variável identificadora do animal (ANIMAL) e a idade (IDADE) também constam no dataset.

3.2. Pré-processamento dos dados

Antes do treinamento dos modelos, os dados passaram por etapas de pré-processamento. Registros com valores ausentes ou inconsistentes foram tratados adequadamente. A variável categórica SEXO foi codificada numericamente para uso nos modelos de classificação (Macho = 1, Fêmea = 0). O conjunto de dados foi dividido aleatoriamente na proporção de 80% para treinamento e 20% para teste, mantendo a proporcionalidade entre as classes.

3.3. Modelagem preditiva

Todos os modelos foram desenvolvidos na linguagem de programação Python, utilizando bibliotecas como scikit-learn e *XGBoost*. Foram implementadas duas tarefas de modelagem:

1. **Regressão:** predição do peso corporal (variável contínua) a partir das medidas corporais, utilizando o algoritmo *XGBoost Regressor*.
2. **Classificação:** predição do sexo (variável categórica binária) a partir das medidas corporais, utilizando dois algoritmos: *XGBoost Classifier* e *Support Vector Machine* (SVM).

3.3.1. XGBoost

O *XGBoost* (Extreme Gradient Boosting) é um algoritmo de aprendizado de máquina baseado em ensemble de árvores de decisão, que utiliza a técnica de *gradient boosting* para construir modelos preditivos de alto desempenho (CHEN E GUESTRIN, 2016).

Esse algoritmo constrói árvores sequencialmente, de modo que cada nova árvore busca corrigir os erros residuais das anteriores. O *XGBoost* incorpora mecanismos de regularização (L1 e L2) para evitar o sobreajuste (*overfitting*), além de ser computacionalmente eficiente e escalável. Neste trabalho, o *XGBoost* foi empregado tanto para a tarefa de regressão (predição do peso corporal) quanto para a tarefa de classificação (predição do sexo), por seu desempenho em dados tabulares.

3.3.2. Support Vector Machine (SVM)

O *Support Vector Machine* (SVM) é um algoritmo de aprendizado supervisionado que busca encontrar o hiperplano ótimo que maximiza a margem de separação entre as classes no espaço de características (VAPNIK, 1995). Para problemas não linearmente separáveis, o SVM utiliza funções de kernel (como o *Radial Basis Function* – RBF) para mapear os dados em espaços de maior dimensionalidade, onde a separação linear se torna possível. Neste estudo, o SVM foi utilizado exclusivamente para a tarefa de classificação do sexo das galinhas-d’angola, por ser bom para a classificação binária.

3.4. Validação e métricas de avaliação

Para garantir a robustez e a generalização dos modelos, foi empregada a técnica de validação cruzada (*cross-validation*), que consiste em particionar os dados de treinamento em subconjuntos complementares, treinando o modelo em parte dos dados e validando-o na parte restante, de forma iterativa.

As métricas utilizadas para avaliar o desempenho dos modelos foram distintas conforme a tarefa:

- Para regressão (predição do peso corporal):
 - **Coefficiente de determinação (R^2):** mede a proporção da variância da variável dependente explicada pelo modelo. Valores mais próximos de 1 indicam melhor ajuste.

- **Raiz do erro quadrático médio (RMSE):** expressa o erro médio de predição na mesma unidade da variável resposta (gramas), penalizando erros maiores de forma mais severa.
- **Erro absoluto médio (MAE):** representa a média dos erros absolutos entre os valores preditos e observados, fornecendo uma medida intuitiva do erro de predição.
- Para classificação (predição do sexo):
 - **F1-Score:** média harmônica entre a precisão e a revocação, sendo particularmente útil em situações onde há desbalanceamento entre as classes.
 - **Matriz de confusão:** representação tabular que permite visualizar os acertos e erros do modelo para cada classe (verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos).

4. Resultados e discussão

Nesta seção são apresentados e discutidos os resultados obtidos com os modelos desenvolvidos. Os experimentos foram organizados em quatro conjuntos complementares. O Experimento 1 avalia a predição do peso corporal com o *XGBoost* e a classificação do sexo com o SVM, analisando o desempenho por faixa etária. O Experimento 2, por sua vez, utiliza o conjunto de dados completo e balanceado, compara múltiplos algoritmos de classificação e analisa a importância das variáveis no modelo *XGBoost*. O Experimento 3 realiza uma comparação sistemática entre múltiplos algoritmos para ambas as tarefas, com separação por animal entre treino e teste. Por fim, o Experimento 4 abandona as medidas corporais e investiga se o padrão de evolução do peso ao longo do tempo é, por si só, capaz de discriminar o sexo das aves. Ao final de cada experimento são apresentadas considerações sobre as limitações observadas.

4.1. Experimento 1

O Experimento 1 foi conduzido com o objetivo de avaliar, de forma preliminar, o desempenho dos modelos nas duas tarefas propostas. Para a predição do peso corporal, empregou-se o *XGBoost Regressor*, enquanto para a classificação do sexo utilizou-se o SVM, ambos avaliados por faixa etária. Os resultados de cada tarefa são apresentados a seguir, seguidos das considerações gerais sobre o experimento.

4.1.1. Predição do peso corporal — XGBoost

O modelo *XGBoost Regressor* apresentou desempenho global elevado na predição do peso corporal das galinhas-d'angola, alcançando $R^2 = 0,9810$ e $RMSE = 68,9$ g no conjunto de teste, considerando todas as idades conjuntamente. A Figura 1 ilustra os resultados obtidos.

Ao analisar o desempenho por faixa etária, observou-se que o coeficiente de determinação variou consideravelmente. A idade de 66 dias apresentou o melhor R^2 individual (aproximadamente 0,91), enquanto as idades iniciais (0 e 28 dias) apresentaram valores mais baixos (R^2 entre 0,13 e 0,24).

Entretanto, esse bom desempenho na idade de 66 dias deve ser interpretado com cautela. A análise da importância das features indicou forte predominância da




Figura 1. Desempenho do XGBoost na predição do peso corporal por faixa etária. (A) R^2 por idade. (B) Valores reais vs. preditos ($R^2 = 0,9810$; RMSE = 68,9 g). (C) Erro absoluto médio (MAE) por idade. (D) Análise de resíduos.

variável PESO_ANTERIOR, sugerindo que o modelo está se apoiando majoritariamente no histórico imediato de peso, em vez de extrair padrões relevantes a partir das medidas morfométricas. Isso limita o poder explicativo do modelo e reduz sua capacidade de generalização em cenários onde essa variável não esteja disponível.

O erro absoluto médio (MAE) apresentou tendência crescente com o avanço da idade, variando de aproximadamente 2 g na idade 0 até cerca de 78 g nas idades 80 e 115 dias. Tal comportamento é esperado, uma vez que a faixa de variação do peso corporal também aumenta com a idade. A análise de resíduos demonstrou distribuição aproximadamente centrada em zero, porém com maior dispersão nas idades mais avançadas.

Nas idades iniciais (0 e 7 dias), medidas como canela, circunferência abdominal e circunferência da cabeça foram mais relevantes. A partir da idade de 14 dias, o PESO_ANTERIOR passou a dominar o modelo, especialmente nas idades mais avançadas (66 a 115 dias), reforçando a dependência dessa variável.

Esses resultados são consistentes com achados da literatura, porém indicam que o elevado R^2 global (0,9810) pode estar parcialmente inflado pela presença de variáveis altamente correlacionadas com a variável alvo, devendo ser interpretado com cautela. Resultados semelhantes foram observados por Urooj et al. (2023), que alcançaram $R^2_{adj} = 0,999$ na predição do peso de frangos Ross 308 com modelo *ensemble*, e por Jahan et al. (2020), com $R^2 = 0,9404$ em codornas japonesas utilizando redes neurais artificiais.

4.1.2. Predição do sexo — SVM

O modelo SVM para classificação do sexo foi treinado e avaliado separadamente para cada faixa etária. Os resultados revelaram desempenho altamente variável conforme a idade das aves (Figuras 2 e 3).

O F1-Score no conjunto de teste variou de 0,000 (idade 52) a 1,000 (idades 21 e




Figura 2. Desempenho do SVM na classificação do sexo por faixa etária. (A) F1-Score de teste e de validação cruzada por idade. (B) F1-Score de todas as configurações avaliadas na melhor idade (21 dias). (C) Distribuição do F1-Score de validação cruzada por rodada. (D) Acurácia, precisão e recall por idade.

115). Embora as idades de 21 e 115 dias apresentem classificação perfeita, esses resultados indicam forte evidência de sobreajuste (*overfitting*), considerando especialmente a discrepância em relação às demais idades.

Na idade de 52 dias, o modelo não obteve nenhum acerto, classificando incorretamente todas as amostras, resultando em F1-Score nulo. Esse comportamento sugere incapacidade do modelo em capturar padrões discriminantes nessa faixa etária, possivelmente devido à ausência de dimorfismo sexual significativo ou à distribuição inadequada dos dados de treino.

As matrizes de confusão evidenciam ainda um viés sistemático do modelo, com maior capacidade de classificação de machos em comparação às fêmeas na maioria das idades (Figura 3).

Apesar de a validação cruzada no conjunto de treino apresentar F1-Score relativamente estável (entre 0,70 e 0,76), os resultados no conjunto de teste mostram inconsistência significativa, reforçando a presença de sobreajuste em idades.

4.1.3. Considerações do Experimento 1

Os resultados do Experimento 1 indicam que o *XGBoost* apresenta bom desempenho na predição do peso corporal, porém com forte dependência da variável PESO_ANTERIOR, o que limita sua interpretação como modelo baseado exclusivamente em medidas morfológicas.




Figura 3. Matrizes de confusão do SVM por faixa etária.

Para a classificação do sexo, o SVM apresentou desempenho inconsistente, com indícios claros de sobreajuste em algumas idades (21 e 115 dias), falha completa em outras (52 dias) e viés na classificação em favor de machos. Esses resultados indicam a necessidade de ajustes nos dados, balanceamento de classes e exploração de modelos alternativos.

A dificuldade na classificação do sexo por medidas morfométricas é recorrente na literatura. Vieira et al. (2009) destacam que ao menos metade das espécies de aves não apresenta dimorfismo sexual evidente, e Cuan et al. (2022) obtiveram acurácia de apenas 91,25% na sexagem de frangos por vocalização, demonstrando limitações dessas abordagens.

4.2. Experimento 2

Diferentemente do Experimento 1, neste experimento foi utilizado o conjunto de dados completo, realizando-se uma separação manual de 20% dos dados para teste, garantindo o balanceamento entre machos e fêmeas. Além disso, foram avaliados múltiplos algoritmos para a tarefa de classificação do sexo, bem como analisada a importância das variáveis no modelo *XGBoost*. Para as tarefas de regressão e classificação finais, utilizou-se o *XGBoost*.

4.2.1. Classificação do sexo — Comparação de modelos

Inicialmente, foram avaliados diferentes algoritmos de classificação com o objetivo de comparar seus desempenhos na predição do sexo das aves. Entre os modelos testados, destacaram-se *XGBoost*, *LightGBM* e *KNN*, que apresentaram os melhores resultados em termos de F1-Score (Figura 4).




Figura 4. Comparação entre modelos para classificação do sexo no Experimento 2. (A) F1-Score por modelo (CV e Teste). (B) Métricas do melhor modelo. (C) Matriz de confusão do melhor modelo. (D) Acurácia por faixa etária para os três melhores modelos.

O modelo *XGBoost Classifier* apresentou o melhor desempenho geral, com F1-Score de aproximadamente 0,744 no conjunto de teste, além de recall elevado (0,974). No entanto, esse alto recall indica que o modelo tende a classificar corretamente a maior parte de uma classe específica, possivelmente às custas de erros na outra classe.

A matriz de confusão do melhor modelo evidencia um forte desbalanceamento nas predições: a grande maioria das fêmeas foi incorretamente classificada como machos (172 erros contra apenas 14 acertos), enquanto os machos foram corretamente classificados em sua maioria (260 acertos).

4.2.2. Predição do peso corporal — XGBoost

Para a predição do peso corporal, foi utilizado um modelo único de *XGBoost* treinado sobre todas as idades. O modelo apresentou bom desempenho global, com $R^2 = 0,9410$ e $RMSE = 113,4$ g no conjunto de teste (Figura 5).




Figura 5. Desempenho do XGBoost na predição do peso corporal no Experimento 2. (A) R^2 por faixa etária. (B) Valores reais vs. preditos ($R^2 = 0,9410$; $RMSE = 113,4$ g). (C) MAE por faixa etária. (D) Análise de resíduos.

A análise por idade revelou comportamento bastante heterogêneo. A idade de 0 dias apresentou desempenho extremamente baixo (R^2 negativo), indicando que o modelo não consegue capturar padrões relevantes nessa fase inicial.

O desempenho obtido é comparável ao reportado por Çakmakçi (2022), com $RMSE = 4,47$ em ovelhas Norduz, e por Bila (2025) em frangos Ross 308. A relevância da circunferência abdominal como principal preditor confirma os resultados de Ogah (2012), que identificou perímetro torácico como melhor preditor isolado ($R^2 = 0,558$) em galinhas-d'angola.

4.2.3. Importância das variáveis — XGBoost

A análise da importância das features no modelo revelou que a circunferência abdominal (CIRCFABDOM) é, de forma destacada, a variável mais relevante para a predição do peso corporal, seguida por dorso, idade e circunferência da cabeça (Figura 6).




Figura 6. Importância das variáveis no modelo *XGBoost* para a predição do peso corporal.

4.2.4. Considerações do Experimento 2

Os resultados do Experimento 2 indicam que, embora o uso do conjunto de dados completo e balanceado melhore a consistência metodológica, ainda persistem limitações importantes. Na classificação do sexo, mesmo os melhores modelos apresentaram viés significativo, com dificuldade em identificar corretamente fêmeas. Na predição do peso corporal, o modelo XGBoost apresentou bom desempenho global, porém inferior ao Experimento 1. Por outro lado, essa abordagem resulta em um modelo mais interpretável e mais robusto.

De forma geral, os resultados sugerem um compromisso entre desempenho e capacidade de generalização.

4.3. Experimento 3

No Experimento 3 foi realizada uma comparação sistemática entre múltiplos algoritmos de aprendizado de máquina para ambas as tarefas — predição do peso corporal e classificação do sexo —, utilizando o conjunto de dados completo, com separação por animal entre treino e teste. O objetivo foi identificar qual família de algoritmos apresenta melhor desempenho no contexto biométrico das galinhas-d'angola ao longo de todo o ciclo de crescimento, sem restrição a uma faixa etária específica.

Em ambas as tarefas, o critério de isolamento por animal foi mantido: 20% dos animais foram reservados para teste (`random_state = 42`), de forma que nenhuma

observação de um mesmo indivíduo ocorra simultaneamente em treino e teste. A busca de hiperparâmetros foi conduzida por *RandomizedSearchCV* em todos os modelos.

4.3.1. Predição do peso corporal — Comparação de modelos

Dez algoritmos de regressão foram avaliados: *Random Forest*, *Extra Trees*, *Gradient Boosting*, *XGBoost*, *LightGBM*, *KNN*, *Ridge*, *Lasso*, *ElasticNet* e *SVR*. Os preditores utilizados foram as treze variáveis morfométricas disponíveis no conjunto de dados (bico, circunferência da cabeça, pescoço, asa, tulipa, dorso, ventre, circunferência abdominal, sobrecoxa, coxa, canela, unha maior e peso), acrescidas da idade (IDADE). Diferentemente do Experimento 1, o peso registrado na mensuração anterior (PESO_ANTERIOR) não foi utilizado como preditor, pois o modelo opera com dados transversais de todo o ciclo de crescimento, sem acesso ao histórico ponderal individual.

A validação cruzada foi conduzida com *KFold* (5 folds), adotando o R^2 como critério de otimização. Para mitigar o desbalanceamento amostral entre faixas etárias, o SMOTE foi aplicado ao conjunto de treino antes do ajuste: o alvo (PESO) foi discretizado em cinco quantis e utilizado como rótulo auxiliar, de modo que as variáveis preditoras e o peso foram interpolados conjuntamente na síntese de amostras.

A Tabela 2 apresenta o R^2 de teste de todos os modelos avaliados. O melhor resultado individual foi obtido pelo *Random Forest* ($R^2_{CV} = 0,9447$; $R^2_{teste} = 0,9453$; RMSE = 107,1 g; MAE = 68,6 g), seguido de perto por *Extra Trees* e *Gradient Boosting*.

Tabela 2. Comparação de algoritmos de regressão para predição de peso corporal.

Rank	Modelo	R^2 Teste
1	Random Forest	0,9453
2	Extra Trees	0,9449
3	Gradient Boosting	0,9419
4	XGBoost	0,9418
5	LightGBM	0,9399
6	KNN	0,9393
7	Lasso	0,9269
8	Ridge	0,9263
9	ElasticNet	0,9235
10	SVR	0,9162

O desempenho global foi elevado e homogêneo entre todos os algoritmos: o intervalo de R^2 variou de 0,9162 (SVR) a 0,9453 (Random Forest), diferença de apenas 2,9 pontos percentuais. Os métodos de *ensemble* baseados em árvores (Random Forest, Extra Trees, Gradient Boosting, XGBoost e LightGBM) concentraram-se entre as cinco primeiras posições, com $R^2 \geq 0,9399$. Os modelos lineares regularizados (Lasso, Ridge, ElasticNet) e o SVR situaram-se nas últimas posições, porém ainda com $R^2 \geq 0,91$, evidenciando forte componente linear na relação entre as medidas morfométricas e o peso.

Contudo, a análise por faixa etária para os três melhores modelos (Figura 7) revela comportamento marcadamente heterogêneo: nas idades de 0 e 7 dias, o R^2 intra-etário co-

lapsa para valores próximos ou negativos, indicando que o modelo não supera um preditor trivial baseado na média do grupo nessas fases. O R^2 global elevado decorre, portanto, da dominância da variável IDADE como preditor: o modelo captura principalmente a progressão ponderal entre faixas etárias, e não as diferenças individuais dentro de cada faixa. Esta limitação estrutural é análoga à observada no Experimento 2 e reforça que a estratificação por idade, adotada no Experimento 1, é essencial para estimativas fidedignas da capacidade preditiva real.




Figura 7. Comparação de algoritmos de regressão para predição de peso corporal. (A) R^2 por modelo (CV e Teste). (B) MAE por modelo. (C) Valores reais vs. preditos pelo melhor modelo (Random Forest; $R^2 = 0,9453$). (D) R^2 por faixa etária para os três melhores modelos.

4.3.2. Classificação do sexo — Comparação de modelos

Oito algoritmos de classificação foram avaliados: *Gradient Boosting*, *Random Forest*, *Extra Trees*, *XGBoost*, *LightGBM*, *SVM*, *KNN* e Regressão Logística. Os preditores incluíram as treze variáveis morfométricas e a idade (IDADE), totalizando catorze variáveis. A validação cruzada foi conduzida com *StratifiedKFold* (5 folds), adotando o F1-Score como critério de otimização, adequado ao desbalanceamento de classes. O SMOTE foi incorporado diretamente ao *pipeline* de cada modelo, sendo aplicado exclusivamente dentro de cada *fold* de treinamento para prevenir vazamento de dados.

A Tabela 3 apresenta o F1-Score de teste de todos os modelos. O melhor resultado

foi obtido pelo *Gradient Boosting*, com $F1_{CV} = 0,6403$, $F1$ de teste = 0,6546, acurácia = 0,5784, precisão $\approx 0,633$ e *recall* $\approx 0,678$.

Tabela 3. Comparação de algoritmos de classificação para predição de sexo.

Rank	Modelo	F1 Teste
1	Gradient Boosting	0,6546
2	Random Forest	0,6448
3	Extra Trees	0,6312
4	XGBoost	0,6250
5	LightGBM	0,6160
6	SVM	0,5896
7	KNN	0,5820
8	Regressão Logística	0,5350

Um resultado particularmente revelador é que a acurácia do melhor modelo (0,5784) ficou abaixo da acurácia do classificador de maioria (*baseline* = 0,5894), indicando que nenhum algoritmo superou a estratégia trivial de predizer sempre a classe predominante em termos de acerto global. O F1-Score superior ao *baseline* reflete que o SMOTE induziu uma redistribuição das predições entre as classes, elevando o *recall* da classe minoritária às custas da acurácia bruta, sem que isso se traduzisse em ganho real de discriminação.

A matriz de confusão do melhor modelo (Figura 8) evidencia o padrão já observado nos experimentos anteriores: elevada taxa de erros na classificação de fêmeas, com a maioria dos indivíduos dessa classe sendo incorretamente classificada como macho. A análise por faixa etária revela acentuada instabilidade: a acurácia dos três melhores modelos oscila entre 0,4 e 0,9 ao longo das dez idades, sem padrão consistente de melhora, resultado análogo ao observado com o SVM no Experimento 1.

4.3.3. Considerações do Experimento 3

O Experimento 3 corrobora e expande os achados dos experimentos anteriores. Na predição de peso, todos os dez algoritmos avaliados atingiram R^2 global superior a 0,91, com os métodos de *ensemble* baseados em árvores liderando o ranking. Todavia, o R^2 global é substancialmente inflado pela amplitude ponderal entre faixas etárias, e o desempenho intra-etário é consideravelmente inferior, em especial nos primeiros dias de vida, padrão consistente com os Experimentos 1 e 2, que reforça a superioridade da abordagem estratificada por idade para estimativas preditivas precisas.

Na classificação do sexo, a avaliação de oito algoritmos distintos confirma que nenhuma abordagem consegue superar o *baseline* de maioria em acurácia, independentemente do algoritmo empregado. Os resultados convergem para a conclusão de que as medidas morfométricas disponíveis não carregam sinal discriminatório robusto entre os sexos na maior parte do ciclo de crescimento das galinhas-d'angola, limitação que não é contornada pela escolha do algoritmo, pelo balanceamento via SMOTE nem pela inclusão do peso corporal como preditor.




Figura 8. Comparação de algoritmos de classificação para predição de sexo. (A) F1-Score por modelo (CV e Teste). (B) Métricas do melhor modelo (Gradient Boosting). (C) Matriz de confusão do melhor modelo. (D) Acurácia por faixa etária para os três melhores modelos.

4.4. Experimento 4

O Experimento 4 parte de uma ideia diferente dos anteriores. Em vez de usar as medidas do corpo da ave, ele tenta descobrir o sexo observando como o peso da ave evolui ao longo do tempo. A pergunta que o algoritmo busca responder é: machos e fêmeas crescem de formas distintas o suficiente para que essa diferença, sozinha, permita classificar o sexo?

Para responder a isso, o histórico de cada ave foi organizado em ordem de idade e novas variáveis foram criadas para descrever o comportamento da curva de crescimento de cada animal. Essas variáveis usam apenas dados passados da própria ave, evitando vazamento de informação do futuro para o presente. A Tabela 4 resume cada uma delas.

Tabela 4. Variáveis criadas a partir da relação entre idade e peso de cada ave.

Variável	O que representa
IDADE	Idade da ave em dias.
PESO	Peso atual da ave em gramas.
PESO_PRED_MA	Média móvel dos 3 últimos pesos, usada como previsão do próximo peso.
PESO_RESID	Diferença entre o peso real e o peso previsto; mostra o quanto a ave fugiu da própria tendência.
GANHO_PESO	Quanto a ave engordou desde a medição anterior.
TAXA_CRESC	Velocidade de crescimento, calculada como GANHO_PESO dividido pela variação de idade.
TAXA_CRESC_MA	Média móvel da taxa de crescimento nas 3 últimas medições.
PESO_ACUM_MA	Média acumulada de todos os pesos passados da ave, que funciona como linha de base do animal.
SLOPE_IA	Inclinação da reta de regressão linear entre PESO e IDADE no histórico da ave.

Depois de criar essas variáveis, o experimento testa oito algoritmos de classificação (*XGBoost*, *LightGBM*, *Random Forest*, *Extra Trees*, *Gradient Boosting*, *SVM*, *KNN* e *Regressão Logística*), todos com busca de hiperparâmetros via *RandomizedSearchCV*, balanceamento por *SMOTE* e separação por animal, ou seja, uma mesma ave nunca aparece ao mesmo tempo em treino e teste.

4.4.1. Resultados

Antes da classificação, o experimento avalia a qualidade da previsão de peso pela média móvel. Os números mostram um erro médio absoluto de 293,74 g e um erro quadrático médio de 329,53 g, valores altos diante da escala de pesos do conjunto, que vai de 32 g a quase 1500 g. Isso já indica que a curva de crescimento é bastante variável dentro do mesmo animal. A comparação dos modelos é apresentada na Tabela 5.

O melhor modelo foi o *Extra Trees*, com F1 de 0,564 no teste e acurácia de 0,558. A linha de base, que consiste em sempre prever a classe majoritária, atinge 0,442 de acurácia, então o modelo fica cerca de 11 pontos percentuais acima desse piso.

Tabela 5. Comparação dos modelos de classificação no Experimento 4, ordenados por F1 no teste.

Modelo	F1 Validação	F1 Teste	Acurácia
Extra Trees	0,633	0,564	0,558
XGBoost	0,594	0,544	0,549
Random Forest	0,610	0,532	0,547
Gradient Boosting	0,613	0,527	0,549
LightGBM	0,616	0,510	0,531
SVM	0,533	0,489	0,503
KNN	0,489	0,487	0,509
Regressão Logística	0,494	0,427	0,475

Observando a matriz de confusão do *Extra Trees*, o modelo acertou 103 fêmeas e 108 machos, mas confundiu 108 fêmeas como machos. A revocação (*recall*) alta (0,647) com precisão baixa (0,500) mostra que ele tende a inclinar suas predições para a classe positiva, errando bastante quando o faz.

O gráfico das curvas de crescimento médio por sexo, apresentado no painel inferior direito da Figura 9, deixa claro o motivo dessa dificuldade. As duas curvas, de machos e fêmeas, estão praticamente sobrepostas em todas as idades. Em outras palavras, na média, a velocidade e o formato do crescimento são quase idênticos entre os sexos, de modo que as variáveis derivadas dessa curva não conseguem separar bem as classes.

4.4.2. Considerações do Experimento 4

O experimento mostra que, mesmo trocando o tipo de informação usada — abandonando as medidas do corpo e olhando apenas para a relação entre idade e peso —, ainda não é possível classificar o sexo das aves com qualidade. O modelo ganha algum sinal sobre a *baseline*, mas fica longe de um resultado prático, e só funciona um pouco porque captura pequenas diferenças individuais, não porque exista um padrão consistente de crescimento por sexo.

Esse resultado reforça a conclusão central da pesquisa: a galinha-d'angola é uma espécie monomórfica, ou seja, machos e fêmeas se desenvolvem com tamanhos e curvas de crescimento muito parecidos, e por isso variáveis morfométricas, sozinhas ou combinadas em *features* de crescimento, não bastam para distinguir o sexo de forma confiável.

4.5. Experimento 5

Os testes anteriores indicaram que o alto valor de R^2 geral na estimativa do peso corporal poderia estar inflado por variáveis muito ligadas ao alvo, que são PESO_ANTERIOR no Experimento 1 e IDADE nos Experimentos 2 e 3. O Experimento 5 testa essa hipótese e, ao mesmo tempo, verifica quantas medidas corporais são realmente necessárias. Duas mudanças principais diferenciam este experimento dos outros: a variável IDADE foi retirada dos preditores e o desempenho passou a ser medido também dentro de cada faixa etária. A base contou com 2.279 registros em onze idades, divididos por animal (190 aves para treino e 48 para teste), usando o ajuste de hiperparâmetros do *XGBoost* por *RandomizedSearchCV* com *KFold* de cinco partes.




Figura 9. Resultados do Experimento 4: comparação dos modelos, métricas do melhor modelo, matriz de confusão e curvas de crescimento por sexo.

4.5.1. Seleção das variáveis mais importantes

Um primeiro modelo, treinado com as doze medidas corporais, organizou as variáveis pela importância de ganho (*gain*). Escolheu-se o menor grupo de variáveis cuja importância somada chegasse a 95%, o que resultou em sete medidas: CIRCFCABDOM (0,538), CIRCFCABECA (0,209), SOBRECOXA (0,063), DORSO (0,059), ASA (0,037), UNHAMAIOR (0,029) e VENTRE (0,025). As cinco medidas deixadas de fora, que foram PESCOCO, COXA, BICO, CANELA e TULIPA, somam apenas 4,1% do peso total. Chama a atenção essa concentração: a circunferência do abdômen e a circunferência da cabeça juntas respondem por 74,7% do resultado, o que concorda com o Experimento 2 e com o trabalho de Ogah (2012), que apontou o perímetro do peito como a melhor medida individual para estimar o peso em galinhas-d'angola.

Treinado de novo apenas com essas sete variáveis, o modelo manteve o mesmo desempenho do conjunto completo ($R^2_{\text{teste}} = 0,9388$ contra 0,9391 com as doze medidas; RMSE de 113,3 g contra 113,0 g), como mostra a Figura 10. A redução no número de variáveis, portanto, não causou perda de precisão.




Figura 10. Experimento 5: seleção das variáveis. (A) Importância por ganho de cada medida, com as sete escolhidas em verde. (B) R^2 de teste e MAE do modelo com todas as variáveis versus apenas as selecionadas.

4.5.2. Desempenho geral e por faixa etária

Mesmo sem ter acesso à idade das aves, o modelo final obteve $R^2_{\text{teste}} = 0,9388$, RMSE = 113,3 g e MAE = 73,7 g, o que representa 13,1% do peso médio no grupo de teste. Esses números são praticamente iguais aos do Experimento 2 ($R^2 = 0,9410$) e bem próximos ao melhor modelo do Experimento 3 ($R^2 = 0,9453$), mostrando que o resultado geral não depende do algoritmo, do uso da idade ou da quantidade de medidas utilizadas.

A análise detalhada por faixa etária, no entanto, mostra um cenário bem diferente (Tabela 6).

A média do R^2 dentro de cada idade foi de $-0,731$, o que significa que, para aves com a mesma idade, o modelo erra mais do que se usássemos apenas a média do grupo

Tabela 6. Experimento 5: desempenho dentro de cada faixa etária no grupo de teste.

Idade (dias)	N	R ²	MAE (g)
0	47	-5,0552	11,6
7	47	-1,8804	13,1
14	48	-0,8536	30,3
21	46	-0,5475	62,9
28	47	-0,7781	82,7
38	47	0,5175	65,3
52	45	0,5062	84,0
66	46	0,1855	121,4
80	43	0,2250	125,4
101	25	-0,3943	175,8
115	26	0,0341	107,6
Média	—	-0,7310	—

para prever o peso. Isso aconteceu em cinco das onze idades analisadas, e apenas aos 38 e 52 dias o valor ficou acima de $R^2 = 0,5$.

A diferença em relação ao R^2 geral de 0,9388 só parece contraditória. Na prática, o modelo aprende muito bem a relação entre o tamanho e o peso durante o crescimento, já que separar um filhote de 40 g de uma ave adulta de 1.500 g é algo simples, e essa grande diferença entre as idades é o que puxa o R^2 geral para cima. O ponto fraco do modelo é diferenciar aves que estão na mesma fase de vida. Vale destacar que tirar a variável IDADE não resolveu esse problema, porque as medidas do corpo aumentam conforme a ave cresce e acabam servindo como um indicativo indireto da idade.

4.5.3. Considerações do Experimento 5

O experimento traz dois pontos principais. Na prática, apenas sete das doze medidas são suficientes para manter a mesma qualidade do modelo completo, e duas delas concentram cerca de 75% da importância, o que torna a coleta de medidas no campo mais simples e rápida.

Em termos de metodologia, o R^2 geral elevado, visto desde o Experimento 1 e comum em outros trabalhos da área, não prova que o modelo é bom para prever o peso de cada animal sozinho, já que ele mede principalmente a curva de crescimento das aves. Ao testar o modelo apenas com aves da mesma idade, que é a situação real de uso em um lote conhecido, os resultados são ruins em média. O modelo serve para estimar o peso esperado para uma fase de crescimento, mas não consegue diferenciar os pesos individuais dentro de um mesmo lote. Por isso, reforça-se a recomendação, já feita no Experimento 3, de usar a análise separada por idade como padrão para apresentar os resultados.

4.6. Experimento 6

Os testes anteriores apresentaram resultados fracos e instáveis na hora de identificar o sexo das aves, mas sempre avaliando apenas a saída dos modelos. O Experimento 6 muda




Figura 11. Experimento 5: desempenho do XGBoost com as variáveis escolhidas. (A) Valores reais vs. previstos. (B) Análise de resíduos. (C) R^2 dentro de cada faixa etária. (D) Erro médio absoluto por faixa etária.

o foco da análise: em vez de testar diferentes classificadores, busca entender se existe alguma informação sobre o sexo nas medidas do corpo, partindo direto dos dados brutos até chegar ao algoritmo. Foram reunidas cinco evidências distintas, cobrindo distribuições por sexo, testes de dimorfismo por faixa etária, projeções de várias medidas juntas, importância das variáveis e curva ROC.

4.6.1. Distribuição das medidas por sexo

Analisando os 2.299 registros, as distribuições de machos e fêmeas são praticamente iguais. No peso corporal (Figura 12), o valor do meio (mediana) para os machos foi de 475,0 g contra 460,0 g para as fêmeas, o que representa uma diferença de apenas 3,3%, valor sem impacto prático diante da variação geral dos dois grupos, que vai de cerca de 160 g a 1.000 g.

O cálculo da correlação entre cada medida e o sexo confirma essa semelhança: todos os catorze valores ficaram entre $-0,004$ (BICO) e $+0,043$ (CANELA). O único resultado estatisticamente significativo a 5% foi o da canela ($r = +0,043$; $p = 0,038$), mas um número tão baixo explica menos de 0,2% da variação do sexo. A Figura 13 destaca essa medida, que foi a mais informativa de todas: a mediana ficou em 5,0 cm para machos e 4,8 cm para fêmeas, gerando caixas quase sobrepostas no gráfico.




Figura 12. Distribuição do peso corporal por sexo, considerando todas as idades.

4.6.2. Diferença entre sexos por faixa etária

Um ponto a se considerar é que as diferenças físicas poderiam aparecer apenas em certas idades e acabar sumindo na análise geral. A Tabela 7 analisa essa possibilidade comparando a média de peso de machos e fêmeas em cada uma das onze idades, por meio do teste de Mann-Whitney.

Em nenhuma das onze idades houve diferença estatisticamente significativa. As variações percentuais foram de $-2,0\%$ a $+6,7\%$ e não mantiveram um padrão fixo, já que em quatro idades as fêmeas foram, em média, mais pesadas que os machos.




Figura 13. Distribuição do comprimento da canela por sexo, sendo esta a variável com maior relação com o sexo em todo o conjunto.

Tabela 7. Diferença de peso entre machos e fêmeas por faixa etária (teste de Mann-Whitney).

Idade (dias)	Machos (g)	Fêmeas (g)	Diferença (%)	<i>p</i> -valor	Significativo?
0	32,1	32,2	−0, 3	0,9327	não
7	84,0	81,8	+2, 8	0,1275	não
14	167,3	170,7	−2, 0	0,2098	não
21	266,3	249,7	+6, 7	0,0666	não
28	410,0	389,7	+5, 2	0,0973	não
38	573,8	554,8	+3, 4	0,1901	não
52	800,6	784,5	+2, 0	0,3534	não
66	987,9	970,2	+1, 8	0,5626	não
80	1157,0	1180,8	−2, 0	0,4413	não
101	1264,4	1286,1	−1, 7	0,4832	não
115	1434,3	1430,6	+0, 3	0,9162	não

O mesmo teste aplicado para cada medida corporal dentro de cada idade gerou 77 comparações, das quais 14 tiveram $p < 0,05$. O total ficou um pouco acima dos quatro casos esperados ao acaso, mas essas diferenças apareceram espalhadas entre idades e medidas sem uma regra clara, e nenhuma se manteve válida após o ajuste de Bonferroni para testes múltiplos (limite de 0,00065, sendo que o menor valor encontrado foi $p = 0,00074$, para a coxa aos 66 dias). A Figura 14 resume essa situação: mesmo combinando as duas medidas mais fortes de cada idade, machos e fêmeas continuam totalmente misturados no gráfico.




Figura 14. Separação dos sexos por faixa etária. Cada gráfico mostra o cruzamento das duas variáveis com menor p -valor naquela idade.

4.6.3. Combinação de múltiplas variáveis

As etapas anteriores avaliaram as medidas uma a uma. No entanto, é possível que a separação entre os sexos só fique visível ao combinar várias características ao mesmo tempo. Para verificar isso, foram usadas duas técnicas de projeção.

A análise de componentes principais (Figura 15) mostra que o primeiro eixo concentra 83,2% de toda a variação dos dados e reflete simplesmente o tamanho geral da ave, ou seja, a sua idade; o segundo eixo explica apenas 3,7%. Com isso, machos e fêmeas ocupam o mesmo espaço no gráfico.

A análise discriminante linear (Figura 16) reforça esse ponto, pois é um método feito justamente para tentar encontrar a melhor combinação para separar os dois grupos. Mesmo assim, as curvas de machos e fêmeas ficaram quase sobrepostas, mudando apenas por um leve desvio nas médias.




Figura 15. Projeção das medidas corporais nos dois eixos principais, com as aves divididas por sexo.




Figura 16. Distribuição de machos e fêmeas ao longo da função de separação dos grupos.

4.6.4. Capacidade de classificação do modelo

Por fim, ajustou-se um modelo *XGBoost Classifier* usando as treze medidas corporais junto com o peso e a idade. A importância de cada variável no modelo (Figura 17) ficou dividida de forma quase igual, variando entre 0,064 e 0,092, faixa bem próxima dos 0,071 esperados caso o peso fosse distribuído igualmente entre as catorze variáveis. Nenhuma característica se destacou para a divisão dos grupos, o que acontece quando os dados não trazem nenhum padrão claro.

A curva ROC (Figura 18) mostra os limites desse modelo: o resultado de AUC foi de 0,602 no grupo de teste e 0,565 na validação cruzada, com acerto geral (acurácia) de 0,557. Como uma escolha totalmente aleatória gera uma AUC de 0,500, o ganho real do modelo sobre a sorte foi de apenas 0,10, valor insuficiente para qualquer uso prático.




Figura 17. Importância de cada variável no modelo *XGBoost Classifier* para identificar o sexo.

4.6.5. Considerações do Experimento 6

Os cinco testes trazem a mesma resposta: os dados de machos e fêmeas se sobrepõem, nenhuma idade traz diferenças físicas claras, a união de várias variáveis não separa os grupos, o peso de cada medida no modelo é quase igual e a taxa de acerto fica próxima da escolha ao acaso. Essas constatações vêm de cinco etapas independentes, desde a análise direta das medidas até a avaliação do modelo final.

Dessa forma, fica claro que o desempenho baixo nos Experimentos 1 a 4 não aconteceu por escolha errada de algoritmo, desequilíbrio na base ou falta de ajuste nos parâmetros: a resposta simplesmente não está nas medidas corporais. Para as medidas




Figura 18. Curva ROC para a identificação do sexo, considerando a classe "Macho" como positiva.

avaliadas, a galinha-d'angola se comporta como uma espécie sem diferenças visíveis entre os sexos, o que concorda com Vieira et al. (2009), que indicam a falta de dimorfismo evidente em pelo menos metade das espécies de aves.

Na prática, isso define o limite da proposta: prever o peso usando medidas do corpo é um caminho viável, mas separar os sexos dessa forma não funciona. Para identificar o sexo, seria necessário recorrer a outros tipos de dados, como o som emitido pelas aves, detalhes nas penas ou testes genéticos.

5. Conclusão

Este trabalho apresentou a aplicação de técnicas de aprendizado de máquina para a predição do peso corporal e classificação do sexo de galinhas-d'angola a partir de medidas morfométricas.

Os resultados indicaram que o modelo *XGBoost* possui elevada capacidade preditiva para o peso corporal, especialmente quando há utilização de variáveis historicamente correlacionadas, como o PESO ANTERIOR. No entanto, verificou-se que essa dependência pode inflar artificialmente o desempenho, reduzindo a interpretabilidade e a capacidade de generalização do modelo. No Experimento 2, ao utilizar um modelo unificado sem essa dependência explícita, observou-se uma leve redução no desempenho, porém com maior robustez e coerência metodológica.

Para a classificação do sexo, os modelos avaliados apresentaram desempenho limitado e inconsistente entre as diferentes idades. Mesmo os melhores algoritmos de

monstraram viés significativo na classificação, com maior acurácia para machos e dificuldade na identificação de fêmeas. Esses resultados sugerem que as medidas morfométricas utilizadas não são suficientemente discriminativas para essa tarefa em todas as fases de desenvolvimento.

De forma geral, os experimentos mostram um compromisso entre desempenho e capacidade de generalização, destacando a importância da seleção adequada de variáveis e da análise crítica dos resultados. Como perspectivas futuras, propõe-se a investigação de novas variáveis, técnicas de balanceamento de dados e a avaliação de modelos mais robustos, visando aprimorar a confiabilidade das predições.

Os resultados evidenciam o potencial do uso de aprendizado de máquina na avicultura, ao mesmo tempo em que destacam limitações importantes relacionadas à qualidade e natureza dos dados, reforçando a necessidade de abordagens híbridas e novos tipos de variáveis.

Referências

Referências

- BILA, L. (2025). Predicting body weight in ross 308 broiler chickens using a data mining algorithm approach. *South African Journal of Animal Science*, 55(6):291–303.
- BOTTINO, F., ARTONI, S. M. B., OLIVEIRA, D., FRANZO, V. S., PACHECO, M. R., ORSI, A. M., and AMOROSO, L. (2006). Influência do dimorfismo sexual sobre a morfologia da siringe de galinha-d'angola (*numida meleagris*). *Ciência Rural*, 36(5):1424–1428.
- ÇAKMAKÇI, C. (2022). Live weight prediction in norduz sheep using machine learning algorithms. *Turkish Journal of Agriculture – Food Science and Technology*, 10(4):587–594.
- CHEN, T. and GUESTRIN, C. (2016). Xgboost: a scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794. ACM.
- DZUNGWE, J. T., GWAZA, D. S., and EGAHI, J. O. (2018). Statistical modeling of body weight and body linear measurements of the french broiler guinea fowl in the humid tropics of nigeria. *Poultry, Fisheries & Wildlife Sciences*, 6(2):1–4.
- JAHAN, M., MAGHSOUDI, A., ROKOUEI, M., and FARAJI-AROUGH, H. (2020). Prediction and optimization of slaughter weight in meat-type quail using artificial neural network modeling. *Poultry Science*, 99(3):1363–1368.
- KOKOSZYŃSKI, D., STĘCZNY, K., ŻOCHOWSKA-KUJAWSKA, J., SOBCZAK, M., KOTOWICZ, M., SALEH, M., and FIK, M. (2022). Effect of variety and sex on the carcass and meat quality traits of guinea fowl (*numida meleagris* l.). *Animals*, 12(21):3070.
- KÜÇÜKTOPÇU, E., CEMEK, B., YILDIRIM, D., SIMSEK, H., ERENŞOY, K., and SARICA, M. (2026). Application of supervised machine learning techniques and digital image analysis to predict live weight in anadolu-t broiler chickens. *Animals*, 16(1):68.

- OGAH, D. M. (2012). In vivo prediction of live weight and carcass traits using body measurements in indigenous guinea fowl. *Biotechnology in Animal Husbandry*, 28(1):137–146.
- OGAH, D. M., YAKUBU, A., MOMOH, M. O., and DIM, N. I. (2022). Multivariate characterisation of morpho-biometric traits of indigenous helmeted guinea fowl (*Numida meleagris*) in Nigeria. *PLOS ONE*, 17(6):e0268631.
- PORTILLO-SALGADO, R. I., CIGARROA-VÁZQUEZ, F. A., RUIZ-SESMA, B., MENDOZA-NAZAR, P., HERNÁNDEZ-MARÍN, A., ESPONDA-HERNÁNDEZ, W., and BAUTISTA-ORTEGA, J. (2021). Prediction of egg weight from external egg traits of guinea fowl using multiple linear regression and regression tree methods. *Brazilian Journal of Poultry Science*, 23(3):001–006.
- REIS, G. L., ALBUQUERQUE, F. H. M. A. R., VALENTE, B. D., MARTINS, G. A., TEODORO, R. L., FERREIRA, M. B. D., MONTEIRO, J. B. N., SILVA, M. A., and MADALENA, F. E. (2008). Predição do peso vivo a partir de medidas corporais em animais mestiços holandês/gir. *Ciência Rural*, 38(3):778–783.
- SALLE, C. T. P., GUAHYBA, A. S., WALD, V. B., SILVA, A. B., SALLE, F. O., and NASCIMENTO, V. P. (2001). Uso de redes neurais artificiais para estimar parâmetros de produção de galinhas reprodutoras pesadas em recria. *Revista Brasileira de Ciência Avícola*, 3(3):257–264.
- TARGINO, L. C. (2015). Viabilidade e oportunidade de mercado na criação de galinhas-d'angola (*Numida meleagris* galeata). Master's thesis, Universidade Federal de Campina Grande, Pombal, PB. Dissertação (Mestrado Profissional).
- UROOJ, M., IQBAL, F., and ZIL-E-HUMA (2023). An ensemble machine learning approach for the prediction of body weight of chickens from body measurement. *Journal of Animal & Plant Sciences*, 33(4):794–804.
- VAPNIK, V. N. (1995). *The nature of statistical learning theory*. Springer, New York.
- VIEIRA, J. N., COELHO, E. G. A., and OLIVEIRA, D. A. A. (2009). Sexagem molecular em aves silvestres. *Revista Brasileira de Reprodução Animal*, 33(2):66–70.